CentraleSupélec

Pôle Projet
Intelligence Artifcielle & ML

Sélection des variables d'intérêt pour le clustering flou

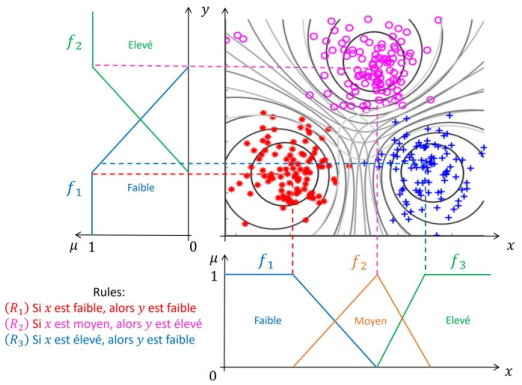

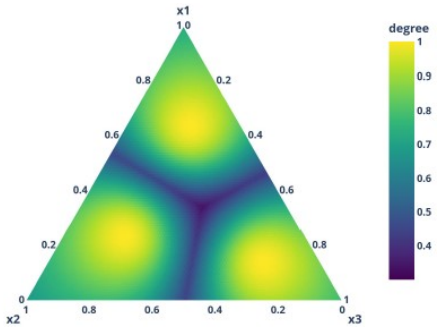

cea list

Description de l'institut de recherche

CEA-LIST

Un institut de recherche du **CEA** spécialisé dans :

- l'**intelligence artificielle** et l'apprentissage automatique,
- la robotique avancée et les systèmes cyber-physiques,
- la réalité virtuelle et la simulation,
- la confiance numérique : cybersécurité, vérification et sûreté des logiciels.

Enjeux

- **Collaboration** industrielle
- **Développement** de technologies de pointe
- **Transfert et valorisation** vers l'industrie.

Description du sujet du projet

Contexte

- Aide à la décision dans les plans expérimentaux en science des matériaux
- Sélection de la prochaine expérience à mener au moyen d'un **algorithme d'apprentissage actif fondé sur le clustering flou**
- **Explication** de la décision par des règles logiques
- **Un cluster** $=$ **une règle logique** : Si $x_1 \wedge x_2$ alors $y = \ldots$

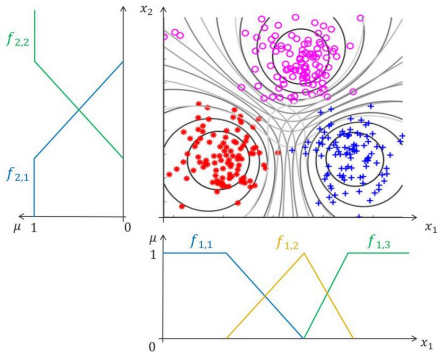

Problématique

- La longueur de la règle est dépendante du nombre de variables du clustering flou
- Avec 100 variables : Si $x_1 \wedge \ldots \wedge x_{100}$ alors $y = \ldots \Rightarrow$ **difficilement interprétable** pour un humain
- **Comment sélectionner les variables d'intérêt dans un cluster ?**

Objectifs

(1) **Déterminer les méthodes** de sélection de variables d'intérêt pour le clustering floue dans la littérature

(2) **Évaluer et comparer** ces méthodes sur l'approche de clustering proposé par le CEA-LIST à partir de plusieurs jeux de données

Attendus et livrables du projet

Deux livrables sont attendus :

Rapport

Un rapport contenant :

- La description des méthodes de sélection identifiées
- La description du protocole d'évaluation des méthodes
- Une discussion des résultats obtenus

Code

L' ensemble du code avec :

- L' implémentation des différentes méthodes de sélection
- L' évaluation des différentes méthodes sur plusieurs jeux de données
- Documentation des différentes étapes de code et des choix proposés

Mise en oeuvre

Technique

- Langage : Python
- Données :
  - Code python de l'algorithme de clustering flou du CEA-LIST
  - Un ensemble de jeux de données synthétiques et réels

Scientifique

Salem Alelyani, Jiliang Tang, and Huan Liu.
Feature selection for clustering : A review.
Data clustering, pages 29–60, 2018.

Olivier Rousselle, Jean-Philippe Poli, and Nadia Ben Abdallah.
Vers une approche floue pour le design de plan expérimental.
In *Conférence Nationale d'Intelligence Artificielle Année 2024*, page 119, 2024.

Client du projet

Organisme

Bâtiment 565,
CEA Saclay,
91191 Gif-sur-Yvette

Correspondants

- **Valentin Fouillard**, Ingénieur-Chercheur
  - (Raisonnement sous incertitude, Logique floue, XAI)
- **Mohamed-Ali Belloum**, Ingénieur-Chercheur
  - (Machine learning, Clustering, Optimisation)
- **Contact :** {prenom.nom}@cea.fr