Sélection de variables pour le clustering non supervisé

Benchmark des méthodes sur données synthétiques

Matthieu Moussaoui Azer Daly Alice Lemaire

Pole Projet IA & ML — CentraleSupelec / CEA-LIST

Encadrants : V. Fouillard, M.-A. Belloum — Année 2025–2026

I. INTRODUCTION

1.1 Problématique

Le clustering non supervisé est confronté à deux pathologies en grande dimension : (i) la *malédiction de la dimensionnalite* — toutes les paires de points tendent à devenir équidistantes, et les clusters indiscernables ; (ii) la *dégradation par bruit* — les variables non informatives perturbent les distances. Pour les pipelines à base de règles floues utilisés dans le projet CEA-LIST, un troisième problème se greffe : chaque règle compte autant de conditions que de variables, et devient illisible dès que $d > 20$. Le seul levier pour préserver l'interprétabilité est de **réduire d avant le clustering**, par une méthode de sélection de variables.

1.2 Positionnement dans la littérature

La sélection de variables non supervisée se décline classiquement en trois familles (Alelyani et al., 2013) : *filter* (critère géométrique indépendant du clustering), *wrapper* (clustering intégré avec régularisation) et *embedded* (sélection conjointe). Nous retenons cinq méthodes couvrant ces trois familles, détaillées en Partie 4 avec la justification de chaque choix. Les méthodes hors périmètre (PCA, sélection par variance seule) sont écartées sur demande du client. Pour les datasets à variables mixtes (catégoriel + continu), Warkiani & Moattar (2025) signalent que les distances euclidiennes sont biaisées : ce point est noté pour `breast_cancer` et fera l'objet d'un traitement distinct.

1.3 Objet du document

Ce document est l'état d'avancement d'une soutenance intermédiaire. Le problème a été **découpé en quatre axes indépendants**, chacun confié à un membre de l'equipe et traité dans une partie dédiée, en correspondance stricte avec un notebook Jupyter :

- **Partie 2** – Analyse et prétraitement des datasets réels (↔ `01_data_analysis_preprocessing.ipynb`).
- **Partie 3** – Quatre algorithmes de clustering (K-Means, Ward, FCM, DBSCAN), illustrés sur données synthétiques 2D (↔ `02_clustering_methods.ipynb`).
- **Partie 4** – Cinq méthodes de sélection de variables *from scratch* (↔ `03_variable_selection.ipynb`).
- **Partie 5** – Métriques et protocole d'évaluation (↔ `04_evaluation_protocol.ipynb`).

1.4 Trois jeux de données distincts

- **Datasets réels du projet** (9 datasets, Partie 2) : décrits, analysés, nettoyés, utilisés pour le benchmark final — pas dans ce document.
- **Datasets synthétiques 2D** (Blobs, Aniso, Moons..., Partie 3) : servent à *visualiser* le comportement géométrique des algorithmes de clustering.
- **Jeu signal/bruit** (Parties 4 et 5) : sert à évaluer les méthodes de sélection en sachant à l'avance quelles variables sont pertinentes.

1.5 Notation

n nombre d'observations, d nombre de variables, $X \in \mathbb{R}^{n\times d}$ matrice de données, $x_i \in \mathbb{R}^d$ observation i, $f_j \in \mathbb{R}^n$ variable j. Pour la sélection : d' variables retenues, $w_j \geq 0$ poids de la variable j. Pour le clustering : k clusters, C_l ensemble des points de C_l, m_l centroide, $r_{il} \in \{0,1\}$ assignation dure, $\mu_{il} \in [0,1]$ appartenance floue.

II. DATASETS DU PROJET & PRÉTRAITEMENT

Implémentation dans `01_data_analysis_preprocessing.ipynb`.

Le projet utilise neuf datasets fournis, répartis en deux catégories : trois datasets de *science des matériaux* (préfixe `MAT_`) et six datasets *Real World* (préfixe `RW_`). Cette partie les décrit, identifie leurs problèmes spécifiques, et fixe le pipeline de prétraitement.

2.1 Vue d'ensemble

Cat.	Dataset	n	d	Tâche	Selec.
MAT	UCI_concrété	1 030	8	regr.	faible
MAT	Li2023	954	16	regr.	faible
MAT	expt_gap	4 604	135	regr.	**forte**
RW	covertype	581k	54	7 cl.	forte
RW	vehicle	846	18	5 cl.	moyen
RW	parkinsons	195	22	2 cl.	forte
RW	diabetes	768	8	2 cl.	faible
RW	breast_cancer	286	9	2 cl.	spécial
RW	glass	214	9	6 cl.	faible

Table 1: Les 9 datasets du projet (chiffres après nettoyage). Pour `covertype`, le benchmark utilisera un sous-échantillon de 5 000 lignes pour la scalabilité.

La colonne *Selec.* indique l'intérêt du dataset pour le benchmark : un dataset à peu de variables (`UCI_concrete`, $d = 8$) vérifié simplement que la sélection ne dégradé pas ; un dataset à beaucoup de variables (`expt_gap`, $d = 135$) est le cas critique pour lequel la sélection est indispensable.

2.2 Datasets matériaux

UCI_concrete (Yeh, 1998). Resistance du béton en MPa à partir de 8 ingrédients quantitatifs. Toutes colonnes numériques, aucune valeur manquante. Cas

propre, sert de référence.

Li2023. Même domaine, 16 variables dont `Coarse Aggregate Type` qui est un entier 1–5 codant 5 types de granulats (calcaire, schiste, granit, basalte, griotte). C'est une *variable catégorielle deguisee en numérique* : la traiter comme ordonnée biaiserait toute distance euclidienne.

expt_gap. *Le dataset critique.* Predit la bande interdite en eV à partir de 135 variables : 103 fractions atomiques (méthode Meredig) + 32 statistiques dérivées. L'analyse exploratoire révélé :

- 37 variables *toujours nulles* (gaz rares, radioactifs absents des matériaux).
- 4 variables quasi-constantes ($>$ 99% de valeurs identiques) : Tc, Pm, Gd, Re.
- 4 paires fortement corrélées (e.g. `mean AtomicWeight` $\leftrightarrow$ `mean Number`, $|\rho| = 0{,}999$).

Un simple filtrage variance + corrélation réduit d de 135 à 91. C'est sur ce dataset que les méthodes avancées sont les plus pertinentes.

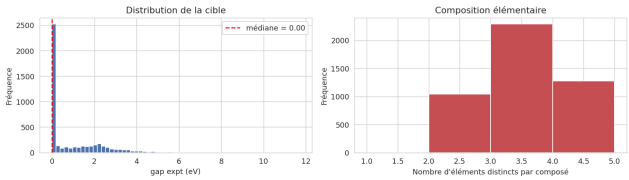

Figure 1: Exploration de `expt_gap`. Gauche : distribution bimodale du *gap* (médiane 1,42 eV) qui révélé deux familles de matériaux — conducteurs ($\approx$ 0 eV) et semi-conducteurs/isolants ($>$ 2 eV). Droite : la plupart des matériaux contiennent 2 a 4 éléments parmi 103 possibles, d'où le grand nombre de fractions atomiques toujours nulles.

2.3 Datasets Real World

covertype. Type de couverture forestière (7 classes) depuis 54 variables continues et binaires. Parmi les 40 binaires de type de sol, 21 sont quasi-constants. Avec 581k lignes, Ward ($\mathcal{O}(n^2)$) y est impraticable.

vehicle. Silhouettes de véhicules (4 classes) depuis 18 mesures géométriques. *Anomalie* : la classe "204 " ne contient qu'un seul échantillon — erreur de saisie a retirer.

parkinsons. Detection de la maladie par 22 mesures vocales. *Déséquilibre* : 75 %/25 %. *Redondance forte* : 26 paires avec $|\rho| > 0{,}9$, dont deux parfaitement identiques (`MDVP:RAP` $= \frac{1}{3}$`Jitter:DDP` et `Shimmer:APQ3` vs `Shimmer:DDA`). A détecter avant tout clustering euclidien.

diabetes. Diagnostic du diabète (Pima, 8 variables). *Piege majeur* : plusieurs colonnes contiennent des zeros qui sont en réalité des valeurs manquantes (BMI, glycemie, tension ne peuvent pas être nuls). En particulier, `Insulin` : 49 % de zeros aberrants. Imputation explicite nécessaire.

breast_cancer. Recurrence du cancer du sein, 8 des 9 variables *catégorielles textuelles*. Cas "spécial " : les méthodes de sélection géométriques y sont peu adaptees (cf. Warkiani & Moattar, 2025), méthodologie distincte requise.

glass. Type de verre (6 classes) depuis 9 mesures de composition chimique. Tout numérique, dataset propre.

2.4 Pipeline de prétraitement

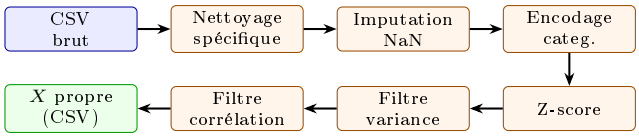

Figure 2: Pipeline applique à chaque dataset. Étapes bleues : I/O. Étapes oranges : transformations.

Les étapes spécifiques couvrent : (i) remplacement des zeros aberrants par NaN dans `diabetes`, (ii) retrait de la classe singleton de `vehicle`, (iii) imputation médiane/mode selon le type, (iv) encodage catégoriel pour `breast_cancer`. La **standardisation Z-score** est indispensable pour les algorithmes euclidiens. Le **filtrage par variance** ($\mathrm{Var}(f_j) < 0{,}1$) et **par corrélation de Pearson** ($|\rho_{jk}| > 0{,}9$, on supprimé celle des deux avec la plus faible variance) finalisent le nettoyage.

2.5 Effet du pipeline

Dataset	d	Cst.	Quasi-cst.	$\lvert\rho\rvert > 0{,}9$
expt_gap	135	37	4	4 paires
parkinsons	22	0	0	26 paires
covertype	54	0	21	0
vehicle	18	0	0	8 paires
Li2023	16	0	0	0
glass, diabetes, UCI_concrété		aucune réduction		
breast_cancer	9	non evaluable (catégoriel)		

Table 2: Variables éliminables par simple prétraitement.

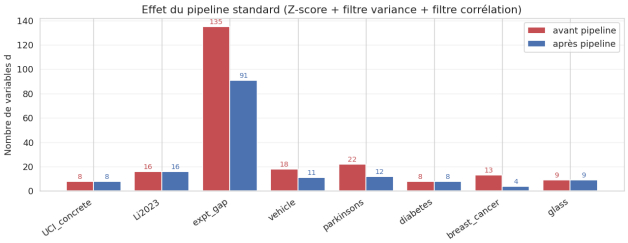

Figure 3: Effet du pipeline standard par dataset. Rouge : avant. Bleu : après. L'écart est substantiel sur `parkinsons` ($-10/22$) et `vehicle` ($-7/18$), modere sur `expt_gap` (-33%), nul sur les datasets déjà propres.

À retenir. Le prétraitement seul fait un nettoyage systématique mais modeste. Sur `expt_gap` il redescend d de 135 à 91 : loin de l'objectif de moins de 20 conditions pour une règle floue lisible. **Seules les méthodes de sélection avancées** (Partie 4) permettent d'aller au-delà.

III. MÉTHODES DE CLUSTERING

Implémentation dans `02_clustering_methods.ipynb`.

3.1 Cadre

Pour caractériser les algorithmes de clustering, on travaille sur des **datasets synthétiques 2D** a structure connue, issus du comparatif scikit-learn : *Blobs* (sphériques), *Aniso* (allonges), *Varied* (variances différentes), *Moons* et *Circles* (non convexes), *No structure* (bruit uniforme).

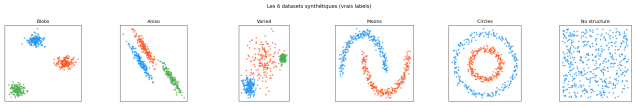

Figure 4: Les 6 datasets synthétiques (couleurs = vrais labels, 500 points chacun).

Quatre algorithmes sont étudiés : K-Means, Ward, Fuzzy C-Means (FCM), DBSCAN. Les trois premiers entrent dans le benchmark ; DBSCAN est présenté pour culture théorique mais reste *hors benchmark* (justification en §3.5).

3.2 K-Means (Lloyd, 1982)

Principe. Placer k centroides $m_1, \ldots, m_k$ tels que chaque point soit aussi proche que possible de son centroide. Partition *dure* : un point, un cluster.

$$J_{KM} = \sum_{i=1}^{n} \sum_{l=1}^{k} r_{il} \, \|x_i - m_l\|^2 \qquad (1)$$

avec $r_{il} \in \{0, 1\}$, $\sum_l r_{il} = 1$, et m_l la moyenne des points du cluster C_l. Plus J_{KM} est faible, plus les clusters sont compacts.

Algorithme de Lloyd. Le problème conjoint en (r, m) est NP-difficile. On alterne deux étapes qui font decroitre J_{KM} de manière monotone : (i) *assignation*, chaque x_i au centre le plus proche, (ii) *mise a jour*, chaque m_l devient la moyenne des points assignes. Convergence garantie vers un *minimum local* ; l'initialisation `k-means++` (Arthur & Vassilvitskii, 2007) limite ce risque.

Complexite : $\mathcal{O}(nkd)$ par itération, typiquement 10–50 itérations. Convient a n très grand.

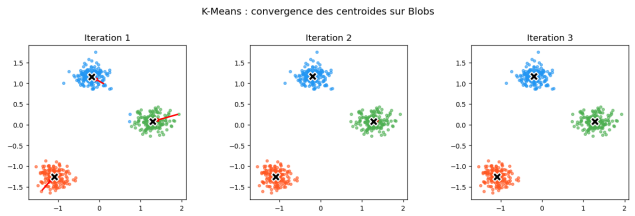

Figure 5: K-Means sur *Blobs* : les centroides convergent en 3 itérations.

Les frontières de décision sont des **cellules de Voronoi** (Fig. 6), toujours linéaires. C'est pour cela que K-Means échoue structurellement sur les formes non convexes (Fig. 7).

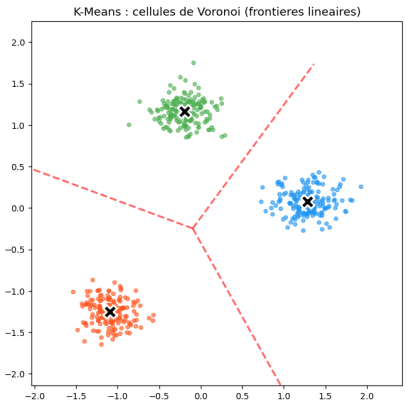

Figure 6: Cellules de Voronoi : frontières linéaires (droites en 2D).

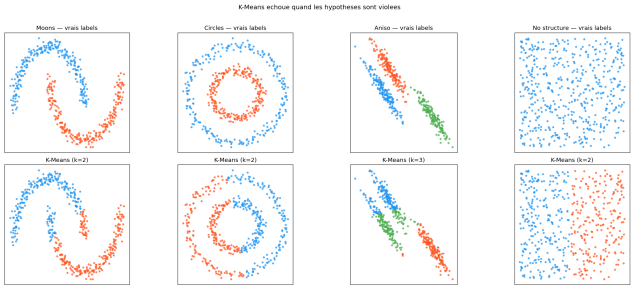

Figure 7: K-Means échoue sur *Moons* et *Circles* (non linéaires), *Aniso* (clusters allonges coupés), *No structure* (clusters inventes).

Choix de k. Méthode du coude (Fig. 8), silhouette, Calinski-Harabasz (cf. Partie 5).

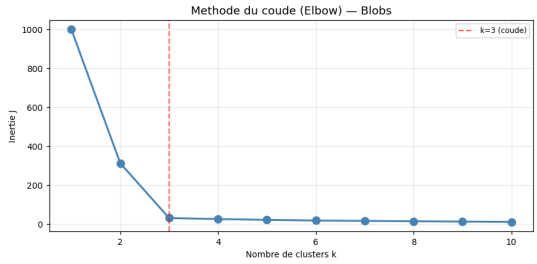

Figure 8: Méthode du coude sur *Blobs* : J_{KM} decroit brutalement jusqu'à $k = 3$ puis plateau. Au-dela, on coupé des clusters réels.

3.3 Clustering hiérarchique : Ward (1963)

Principe. Construire un *dendrogramme* qui contient toutes les partitions possibles : on demarre avec n singletons, on fusionne les deux plus proches, on répété. On coupé l'arbre à la hauteur voulue pour obtenir k clusters — sans recalculer.

Les quatre linkages. La distance entre clusters n'est pas unique :

- **Single** : $\min_{x \in C_a, y \in C_b} \|x - y\|$. Chainage, suit les formes allongees.
- **Complete** : $\max_{x,y} \|x - y\|$. Clusters compacts, sensible aux outliers.
- **Average** : distance moyenne inter-clusters. Compromis.
- **Ward** : minimisé l'augmentation d'inertie :

$$d_{\text{Ward}}(C_a, C_b) = \frac{|C_a| \cdot |C_b|}{|C_a| + |C_b|} \, \|m_a - m_b\|^2 \qquad (2)$$

Le facteur $|C_a||C_b|/(|C_a| + |C_b|)$ pénalisé les fusions de gros clusters. Ward minimisé la même fonction objectif que K-Means : *c'en est l'équivalent hiérarchique*, privilegiant des partitions équilibrées et compactes.

Complexite : $\mathcal{O}(n^2 \log n)$ en temps, $\mathcal{O}(n^2)$ en memoire. Impraticable au-delà de $n \approx 10^5$ — exclut Ward sur `covertype`.

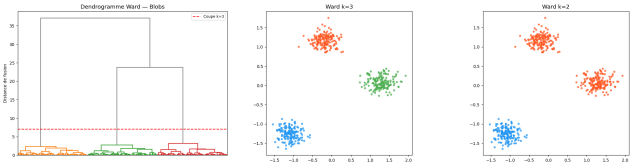

Figure 9: Dendrogramme Ward sur *Blobs*. Un seul calcul donne toutes les partitions : la coupé a $k = 3$ (centre) ou $k = 2$ (droite) est un choix *a posteriori* guide par les sauts verticaux du dendrogramme.

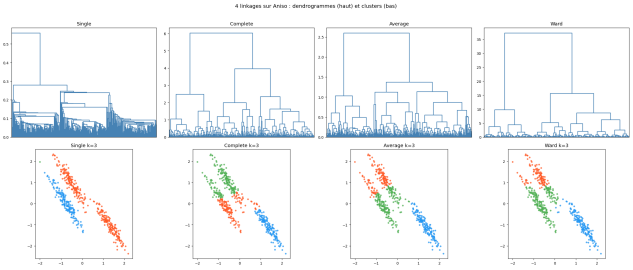

Figure 10: Les 4 linkages sur *Aniso*. *Single* suit la diagonale par chaînage ; *Ward* découpé en blobs sphériques (comme K-Means) ; *complète* et *average* sont des compromis.

3.4 Fuzzy C-Means (Bezdek, 1984)

Principe. La ou K-Means impose $r_{il} \in \{0, 1\}$, FCM produit une **partition floue** : chaque point appartient a tous les clusters avec un degre $\mu_{ci} \in [0, 1]$, sous $\sum_c \mu_{ci} = 1$. C'est essentiel pour le pipeline CEA : chaque cluster génère une règle floue, et μ_{ci} pondéré la contribution de chaque règle dans le système de Sugeno.

$$J_{FCM} = \sum_{i=1}^{n} \sum_{c=1}^{k} \mu_{ci}^{m} \, \|x_i - m_c\|^2 \tag{3}$$

$m > 1$ est le *fuzzifier* : $m \to 1^+$ donne K-Means ; $m = 2$ est le compromis standard ; $m \to \infty$ dissout la structure ($\mu \to 1/k$).

Mises a jour alternees. A m_c fixés, la minimisation sous contrainte donne :

$$\mu_{ci} = \left(\sum_{c'=1}^{k} \left(\frac{\|x_i - m_c\|}{\|x_i - m_{c'}\|} \right)^{\frac{2}{m-1}} \right)^{-1} \tag{4}$$

A μ fixés, m_c est la moyenne *pondérée* $m_c = \sum_i \mu_{ci}^m x_i / \sum_i \mu_{ci}^m$.

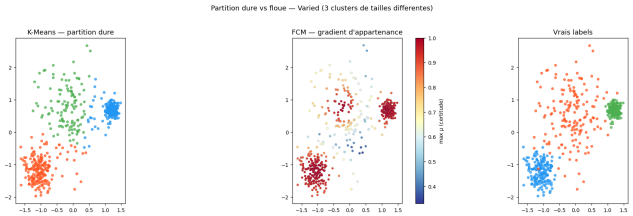

Figure 11: K-Means dur vs. FCM flou sur *Varied*. Le panneau central encodé la *certitude d'appartenance* (rouge $\mu \approx 1$, bleu $\mu \approx 0{,}5$) : FCM révélé les points ambigus que K-Means force a choisir.

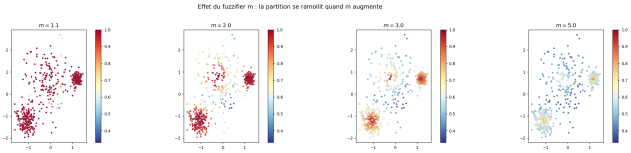

Figure 12: Effet du fuzzifier m. $m = 1{,}1$: quasi-dur. $m = 2$: référence. $m = 5$: quasi-uniforme. Le choix $m = 2$ est assez flou pour capter les ambiguites, assez net pour que les clusters aient un sens.

3.5 DBSCAN (Ester, 1996) — hors benchmark

Principe. Les clusters sont des *regions denses* séparées par des zones de faible densité. Un point est *core* si son ε-voisinage contient au moins minPts points ; un cluster est un ensemble maximal de *cores* densité-connectes, augmente des *border points*. Le reste est bruit.

Parametres : ε (choisi par *k-distance plot*) et minPts $\geq d + 1$. **Complexite** : $\mathcal{O}(n \log n)$ avec KD-tree.

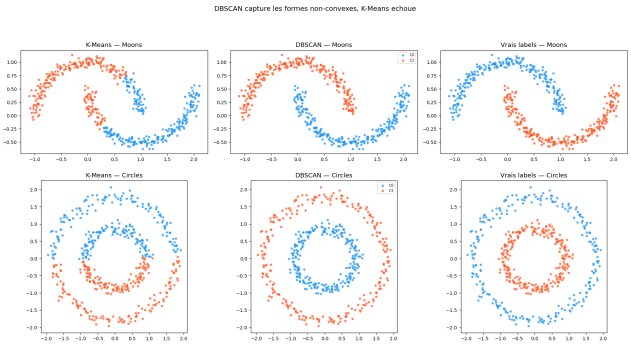

Figure 13: DBSCAN réussit sur *Moons* et *Circles* là où K-Means échoue.

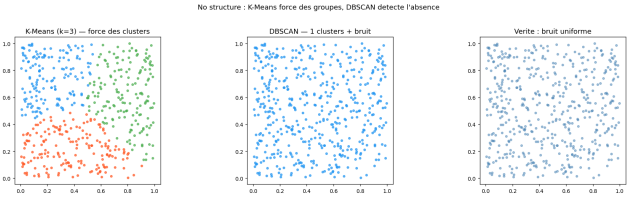

Figure 14: Sur *No structure*, DBSCAN détecté l'absence de structure ; K-Means invente.

Pourquoi hors benchmark. DBSCAN est incompatible avec le pipeline de règles floues du CEA : (i) *pas de centroides* donc aucun prototype pour les règles de Sugeno $\hat{y}(x) = \sum_c \mu_c(x)(\alpha_c^\top x + \beta_c)$, (ii) *pas de partition floue*, (iii) *points bruit non assignes*, (iv) *très sensible a ε en haute dimension*. DBSCAN reste utile en exploration mais sort du benchmark.

3.6 Comparaison synthétique

	K-Means	**Ward**	**FCM**	**DBSCAN**
Famille	Partit. dur	Hierarch.	Partit. flou	Densite
Param.	k	k, link.	k, m	ε, minPts
Forme	sphere	sphere (W)	sphere	arbitr.
Complexite	$\mathcal{O}(nkd)$	$\mathcal{O}(n^2 \log n)$	$\mathcal{O}(nkd)$	$\mathcal{O}(n \log n)$
Outliers	Non	Non	Non	**Oui**

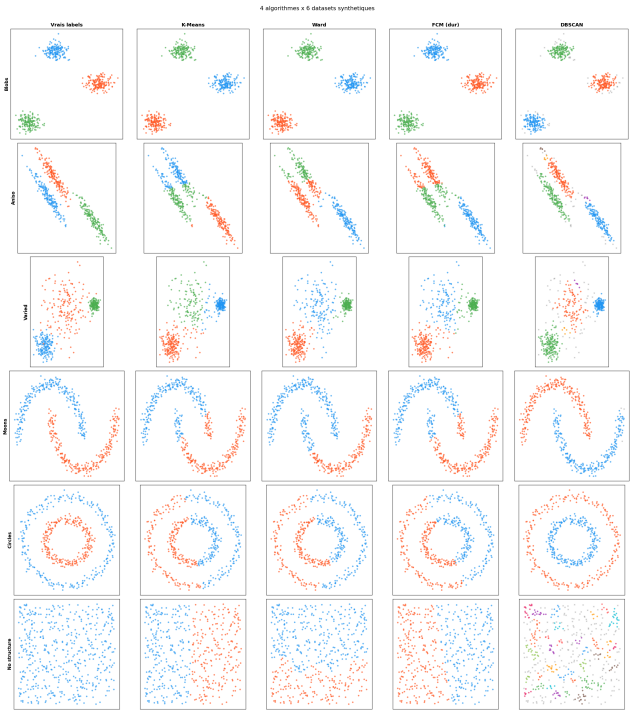

Figure 15: Grille comparative : 4 algorithmes × 6 datasets. *Blobs* : tous réussissent. *Aniso* : K-Means/Ward/FCM coupent les ellipses, DBSCAN s'adapte. *Varied* : K-Means égalisé les tailles. *Moons/Circles* : seul DBSCAN réussit. *No structure* : les trois premiers inventent des clusters, DBSCAN détecté l'absence.

Pipeline retenu pour le projet : FCM initialisé par Ward. Ward fournit des centres initiaux déterministes (pas d'alea), FCM apporte la partition floue indispensable au système de Sugeno. K-Means et Ward seuls servent à tester la robustesse de la sélection. DBSCAN reste hors benchmark.

IV. MÉTHODES DE SÉLECTION DE VARIABLES

Implémentation dans `03_variable_selection.ipynb`.

4.1 Cadre et principe général

4.1.1 Deux jeux de données pour illustrer

Pour expliquer les méthodes, on utilise deux jeux :

- **Jeu pédagogique** : 5 points A, B, C, D, E en 2D, avec une variable signal (qui cluster bien) et une variable bruit (qui cluster mal). Utilise pour les schémas et les calculs à la main.
- **Jeu réaliste** : 300 points répartis en 3 clusters avec 10 variables (2 signal + 8 bruit standardisées). Utilise pour afficher les scores finaux.

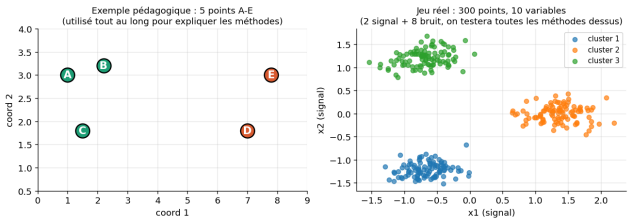

Figure 16: Les deux jeux de données du notebook. A gauche, le fil rouge pédagogique (5 points). A droite, le jeu sur lequel on fait tourner les méthodes (300 points, 10 variables).

4.1.2 Deux grandes familles

Les cinq méthodes étudiées se regroupent naturellement en deux familles :

- **Famille A — méthodes spectrales** : Laplacian Scores, SPEC, MCFS. Elles partagent le même outil, un graphe de voisinage et son Laplacien. Chaque méthode extrait plus d'information du même objet.
- **Famille B — méthodes a poids de variables** : Sparse K-Means, FWKM. Elles modifient K-Means en pondérant chaque variable dans le calcul de la distance.

Le *dilemme fondamental* de la sélection non supervisée est circulaire : *pour trouver les bonnes variables, il faudrait connaître les clusters ; pour trouver les clusters, il faudrait connaître les bonnes variables.* Chaque famille résout ce dilemme a sa façon.

4.2 Famille A — Méthodes spectrales

Les trois méthodes de cette famille partagent l'outil de base : un *graphe de voisinage* et son *Laplacien*.

4.2.1 L'outil commun : matrice S et vecteur D

Matrice de similarité S (taille $n \times n$) : chaque case S_{ij} indique *a quel point les points i et j sont proches.* On relié chaque point a ses voisins proches (par k-NN ou par un seuil de distance), puis on pondéré par un noyau gaussien. Les points non voisins ont $S_{ij} = 0$.

Vecteur des degres D (taille n) : $D_i = \sum_j S_{ij}$. C'est la *connectivité* du point i : grand si le point est bien entoure, petit si le point est isolé.

Laplacien L : $L = \mathrm{diag}(D) - S$. C'est l'outil mathematique qui permet, en une seule opération, de mesurer a quel point une quantite varie le long du graphe.

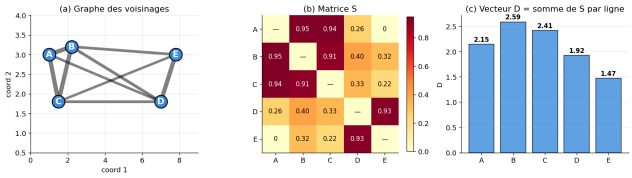

Figure 17: Les trois objets de base, illustrés sur les 5 points. A gauche : le graphe relié les points proches. Au milieu : la matrice S (rouge = proches, blanc = pas voisins). A droite : le vecteur D = somme de chaque ligne de S.

4.2.2 Laplacian Scores (He et al., 2005)

Type. *Filter.* Pas de clustering, un score par variable.

Question posee à chaque variable : *est-ce que mes points voisins sur le graphe ont des valeurs proches ?*

Une variable informative doit être *lisse sur le graphe* : si deux points sont voisins dans l'espace complet, leurs valeurs sur la variable doivent être proches aussi. Une variable qui saute entre voisins est du bruit.

$$\mathrm{LS}_j = \frac{\sum_{i,k} S_{ik}\,(f_{j,i} - f_{j,k})^2}{\sum_i D_i\,(f_{j,i} - \bar{f}_j)^2} \tag{5}$$

En une phrase. Numerateur : somme des sauts entre voisins pondérés par la proximité S. Denominateur : variance totale pour normaliser. *Scores bas = variable pertinente.*

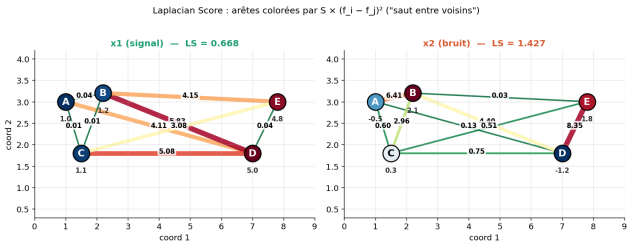

Figure 18: Laplacian Scores sur les 5 points. A gauche, la variable *signal* : les voisins ont des valeurs proches, les aretes sont vertes et fines, LS = 0,67. A droite, la variable *bruit* : les aretes rouges et épaisses signalent de gros sauts entre voisins, LS = 1,43. On garde les variables au score le plus bas.

4.2.3 SPEC (Zhao & Liu, 2007)

Type. *Filter*, généralisation du Laplacian Scores.

Nouvelle idée. Plutot que de comparer les valeurs paire par paire, on extrait les *motifs naturels des clusters*, puis on demande à chaque variable si elle suit un de ces motifs.

D'ou sortent ces motifs. Les *vecteurs propres* du Laplacien donnent, pour chaque point, un nombre tel que les voisins connectes aient des valeurs proches. Le premier vecteur propre v_1 est trivial (tous pareils, on le jette). Les suivants $v_2, v_3, \ldots$ separent progressivement les groupes : chacun est une *image fantome des clusters*, trouvée automatiquement par les maths. Pour k clusters, on prend $v_2, \ldots, v_k$.

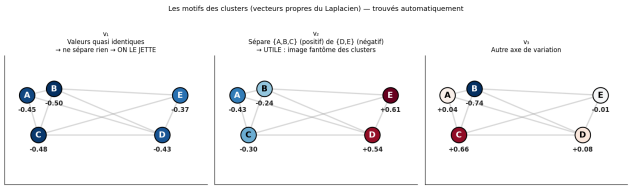

Figure 19: Les vecteurs propres du Laplacien sur les 5 points, colories sur le graphe. v_1 est constant partout (ne séparé rien). v_2 séparé bien {A,B,C} (bleu) de {D,E} (rouge) — c'est le motif des clusters. v_3 capte une autre direction de variation.

$$\mathrm{SPEC}_j = 1 - \max_{l \in \{2,\ldots,k\}} \left(\hat{f}_j^\top v_l\right)^2 \tag{6}$$

En une phrase. $\hat{f}_j^\top v_l$ mesuré a quel point la variable *ressemble* au motif v_l. On prend le maximum sur tous les motifs, car une variable utile pour *un seul* cluster merite d'être gardee. *Scores bas = variable pertinente.*

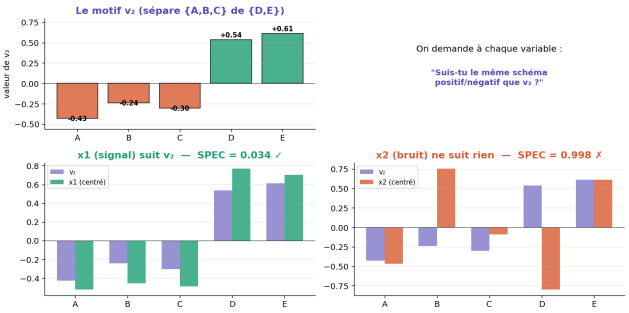

Figure 20: SPEC sur les 5 points. En haut, le motif v_2 séparé {A,B,C} (negatif) de {D,E} (positif). En bas a gauche, x_1 (signal) suit exactement ce schéma — score SPEC = 0,03. En bas a droite, x_2 (bruit) ne suit aucun schéma — score SPEC = 0,998.

4.2.4 MCFS (Cai et al., 2010)

Type. *Filter* spectrale + régularisation (ℓ_1).

Nouvelle idée. Au lieu de tester chaque variable *separement* contre v_l, on les met *toutes ensemble* dans une régression LASSO et on laisse celle-ci décider lesquelles sont nécessaires pour reconstruire v_l.

$$\hat{w}_l = \arg\min_{w \in \mathbb{R}^d} \|v_l - Xw\|_2^2 + \alpha \|w\|_1 \tag{7}$$

La pénalité ℓ_1 force la plupart des coefficients a être *exactement zéro*. Seules les variables indispensables pour reconstruire v_l gardent un coefficient non nul.

Scores final. $\mathrm{MCFS}_j = \max_{l=2,\ldots,k} |\hat{W}_{jl}|$: on garde une variable si elle est utile pour *au moins un* motif. *Scores haut = variable pertinente.*

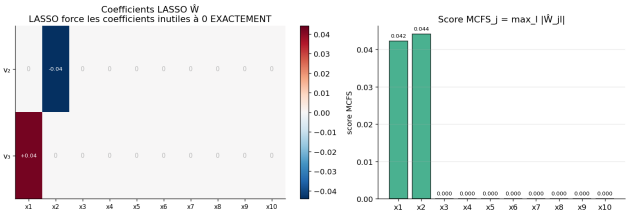

Figure 21: MCFS sur le jeu 300 points. A gauche, la heatmap des coefficients LASSO $\hat{W}$ (10×2) : seules x_1 et x_2 ont des coefficients non nuls, toutes les variables bruit sont à zéro exactement. A droite, le score MCFS = max ligne par ligne.

Différence avec SPEC. SPEC teste chaque variable indépendamment : si deux variables redondantes ressemblent au motif, SPEC les garde toutes les deux. MCFS les met en competition dans la régression : le LASSO n'en garde qu'une, eliminant les doublons.

4.3 Famille B — Méthodes a poids de variables

Plutot que de calculer un score a posteriori, ces méthodes *modifient K-Means* en ajoutant un poids w_j à chaque variable dans le calcul de la distance :

$$\mathrm{dist}(x_i, m_l) = \sum_j w_j \left(x_{ij} - m_{lj}\right)^2 \tag{8}$$

Si $w_j = 0$ (ou petit), la variable j est *ignoree* (ou peu prise en compte) dans le clustering. Le problème : comment trouver les bons poids sans connaître les clusters ? Les deux méthodes *alternent* : clusters → poids → clusters → ...

4.3.1 Sparse K-Means (Witten & Tibshirani, 2010)

Type. *Wrapper.*

Critère. Les bons poids sont ceux qui rendent les *centres des clusters les plus éloignés possible* (maximisation de la dispersion inter-clusters).

Pour chaque variable, on calcule sa *contribution* inter-cluster $a_j = \sum_c |C_c|(m_{cj} - \bar{x}_j)^2$. On applique ensuite un *soft-thresholding* : les contributions sous un seuil Δ deviennent des poids *exactement nuls*.

$$w_j = \frac{(a_j - \Delta)^+}{\|(a - \Delta)^+\|_2} \quad \text{avec} \quad \|w\|_1 \leq s \tag{9}$$

En une phrase. Les variables dont les centres de clusters sont proches ne contribuent rien : le seuil les met à zéro définitivement. *D'où le nom "sparse "* : beaucoup de poids sont zéro.

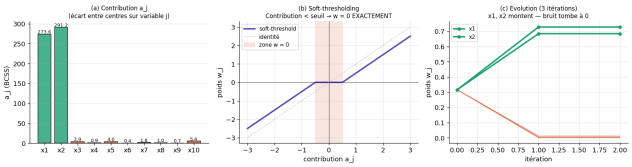

Figure 22: Sparse K-Means sur le jeu 300 points. A gauche, les contributions a_j sont énormes pour x_1 et x_2 (signal), minuscules pour le bruit. Au milieu, le soft-thresholding coupé à zéro tout ce qui est sous le seuil Δ. A droite, l'evolution des poids : x_1 et x_2 montent, les 8 bruits tombent à zéro en une seule itération.

4.3.2 FWKM (Modha & Spangler, 2003)

Type. *Embedded.*

Critère dual de Sparse K-Means. Au lieu de regarder si les centres sont éloignés, on regarde si les points d'un même cluster ont des valeurs *proches* (minimisation de la dispersion intra-cluster).

$$w_j = \frac{1/D_j}{\sum_{j'} 1/D_{j'}} \quad \text{avec} \quad D_j = \sum_c \sum_{i \in C_c} (x_{ij} - m_{cj})^2 \tag{10}$$

En une phrase. D_j est la dispersion totale à l'intérieur des clusters sur la variable j. Le poids est inversement proportionnel : une variable peu dispersée obtient un gros poids, une variable éparpillée un petit poids.

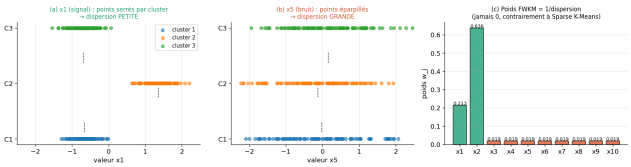

Figure 23: FWKM sur le jeu 300 points. A gauche, sur x_1 (signal) les points de chaque cluster sont serres autour de leur centre — dispersion petite. Au milieu, sur x_5 (bruit) les points sont éparpillés — dispersion grande. A droite, les poids finaux : x_1 et x_2 dominent, les bruits ont des poids faibles mais *jamais nuls*.

Différence fondamentale avec Sparse K-Means. Sparse K-Means *supprimé* totalement les variables bruit (poids = 0 pile), FWKM les *assouplit* (poids très petits mais positifs). C'est un compromis utile quand certaines variables faiblement utiles apportent quand même de l'information.

Avantage majeur pour le projet CEA. FWKM est la *seule des cinq méthodes* qui s'étend directement au Fuzzy C-Means en remplaçant les indicatrices $r_{il} \in \{0, 1\}$ par les appartenances floues $\mu_{il}^m \in [0, 1]$:

$$D_j^{\text{FCM}} = \sum_{i,l} \mu_{il}^m (x_{ij} - m_{lj})^2 \tag{11}$$

La règle de mise a jour $w_j \propto 1/D_j$ reste identique.

4.4 Synthese

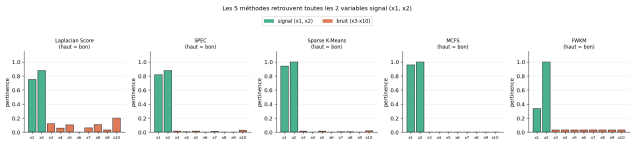

Figure 24: Resultat visuel des 5 méthodes sur le jeu 300 points. Les scores ont été orientés de manière uniforme ("haut = bon "). Toutes les méthodes identifient x_1 et x_2 comme les deux variables signal. Les différences se jouent sur la finesse du classement du bruit.

Méthode	Famille	Critère	Poids 0 ?
Laplacian Scores	filter spectrale	lissage sur graphe	—
SPEC	filter spectrale	alignement avec motif	—
MCFS	filter spectrale	reconstruction par LASSO	oui
Sparse K-Means	wrapper	écart centres (inter)	oui
FWKM	embedded	dispersion intra	non

Table 3: Synthese des cinq méthodes.

Orientation pour le projet CEA. Les méthodes spectrales (LS, SPEC, MCFS) sont des *filtres* rapides qui fournissent un bon classement de variables avant clustering. Sparse K-Means éliminé drastiquement (poids = 0). FWKM est la seule méthode *nativement compatible avec le Fuzzy C-Means*, ce qui la rend indispensable pour l'extension au système de règles de Sugeno qui constitue la finalité du projet.

V. MÉTRIQUES ET PROTOCOLE D'ÉVALUATION

Implémentation dans `04_evaluation_protocol.ipynb`.

5.1 Vue d'ensemble

L'évaluation repose sur trois catégories de métriques : *internes* (sans vérité terrain), *externes* (avec vérité terrain), et *spécifiques au projet* (longueur de règle, score pénalisé). Un protocole en quatre étapes articule ces métriques pour produire un classement rigoureux des méthodes.

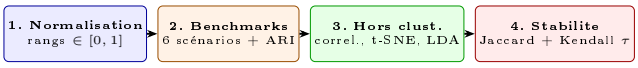

Figure 25: Les quatre étapes du protocole d'évaluation. Chacune répond à une question différente ; aucune ne suffit seule.

5.2 Métriques internes

Silhouette Scores. Pour $x_i \in C_k$, on compare cohésion $a(i)$ (distance moyenne a son cluster) et séparation $b(i)$ (au cluster voisin le plus proche) :

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \in [-1, 1] \tag{12}$$

$s(i) \approx +1$: bien place. $s(i) < 0$: mieux place ailleurs. La silhouette globale est la moyenne $\bar{s} = \frac{1}{n}\sum_i s(i)$.

Davies-Bouldin (DB).

$$DB = \frac{1}{k}\sum_{i=1}^{k} \max_{j \neq i} \frac{S_i + S_j}{\|m_i - m_j\|} \tag{13}$$

avec S_i la dispersion moyenne du cluster i. Le ratio est grand pour des clusters étalés ou proches. *Plus DB est bas, mieux c'est.*

Calinski-Harabasz (CH).

$$CH = \frac{\mathrm{tr}(B_k)}{\mathrm{tr}(W_k)} \cdot \frac{n-k}{k-1} \tag{14}$$

Rapport dispersion inter/intra, corrigé par $(n-k)/(k-1)$. *Plus CH est élevé, mieux c'est.*

5.3 Métriques externes (vérité terrain)

Adjusted Rand Index (ARI). Pour chaque paire de points, on compare la partition predite U et la vraie partition V. L'ARI *ajuste pour le hasard* :

$$\mathrm{ARI} = \frac{RI - \mathbb{E}[RI]}{\max(RI) - \mathbb{E}[RI]} \in [-1, 1] \tag{15}$$

ARI $= 1$: parfait. ARI ≈ 0 : aléatoire. L'ajustement est crucial car sans lui, mettre tous les points dans un seul cluster donnerait RI artificiellement positif.

Normalized Mutual Information (NMI).

$$\mathrm{NMI}(U, V) = \frac{2\, I(U;V)}{H(U) + H(V)} \in [0, 1] \tag{16}$$

$I(U;V)$ est l'information mutuelle, H l'entropie. NMI est moins sensible à la taille des clusters que l'ARI.

5.4 Métriques spécifiques au projet

Longueur de règle d'. C'est la métrique *centrale* : nombre de variables conservees après sélection. Passer de $d = 135$ a $d' = 10$ ramene les règles floues de 135 à 10 conditions. A minimiser.

Ratio de réduction : d'/d. Pour `expt_gap`, $d' = 10$ donne 7,4 %.

Scores CEA pénalisé :

$$\mathrm{Scores}(k') = \mathrm{Silhouette}(k') - \lambda \frac{k'}{d} \tag{17}$$

λ arbitre entre qualité et compacite ($\lambda = 0{,}3$ indicatif, à valider). Le k' qui maximise ce score est le compromis optimal.

5.5 Protocole en quatre étapes

5.5.1 Étape 1 : normalisation en rangs

Probleme. Les 5 méthodes produisent des scores sur des échelles différentes (LS/SPEC dans $[0, 1]$ avec "bas = bon" ; SKM/MCFS/FWKM avec "haut = bon", échelles arbitraires). Les comparer directement n'a aucun sens.

Solution. La seule information stable d'une méthode à l'autre est l'*ordre* qu'elle induit. On convertit en rang normalisé :

$$\mathrm{rang_norm}(j) = \frac{\mathrm{rang}(j) - 1}{d - 1} \in [0, 1] \tag{18}$$

avec $\mathrm{rang}(j) = 1$ pour la variable la plus pertinente.

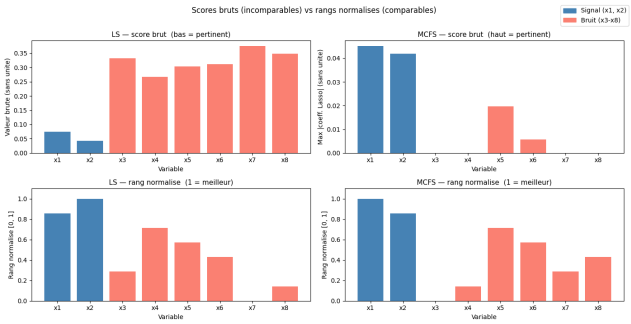

Figure 26: Scores bruts vs. rangs normalisés. Haut : scores absolus incompatibles (LS entre 0 et 0,4, MCFS entre 0 et 0,05). Bas : après conversion en rang normalisé, x_1, x_2 sont clairement aux rangs 1–2 dans les deux méthodes. La conversion en rangs est indispensable pour toute agregation.

5.5.2 Étape 2 : benchmarks synthétiques contrôlés

Sur données réelles on ignore les variables pertinentes. Les données synthétiques règlent le problème : on *choisit* les variables signal et on mesure si les méthodes les retrouvent. Six scénarios font varier trois axes de difficulté.

Scen.	Description	`std`	`n_bruit`	k
S1	Référence facile	0,8	2	3
S2	Standard	1,5	8	3
S3	Clusters étalés	2,5	8	3
S4	Haute dim. de bruit	1,5	20	3
S5	Plus de clusters	1,5	8	5
S6	Cas extrême	2,5	20	2

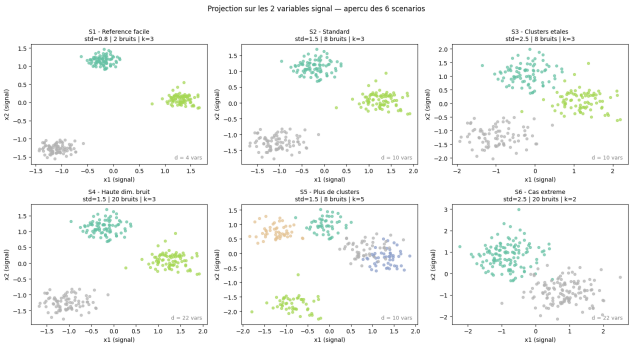

Figure 27: Les 6 scénarios synthétiques projetés sur (x_1, x_2). De S1 (facile, clusters très séparés) à S6 (extrême, clusters étalés dans un bruit dense).

Metrique. ARI post-sélection : on retient les $k' = 2$ meilleures variables, on applique K-Means, on compare aux vrais labels.

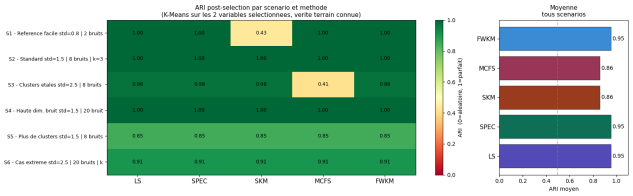

Figure 28: ARI post-sélection. Gauche : heatmap par scénario × méthode. Droite : ARI moyen. Toutes les méthodes réussissent les scénarios faciles (S1, S2, S4 avec ARI ≈ 1). SKM échoue ponctuellement sur S1 (ARI $= 0{,}43$) et MCFS sur S3 (ARI $= 0{,}41$) : ces deux méthodes avec seuil dur peuvent rater quand le signal est faible. LS, SPEC et FWKM restent stables sur tous scénarios (ARI moyen $=$ 0,95 contre 0,86 pour SKM/MCFS).

Formes non gaussiennes. Les scénarios utilisent `make_blobs`, ce qui peut avantager les méthodes spectrales. On teste donc quatre formes alternatives.

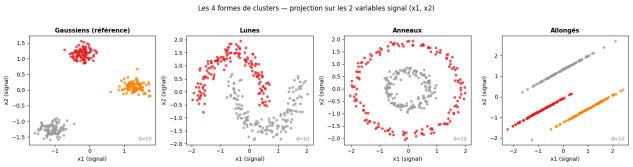

Figure 29: Les 4 formes testees : gaussiens (référence), lunes entrelacées, anneaux concentriques, clusters allonges. Les trois dernières violent l'hypothèse de séparabilité linéaire.

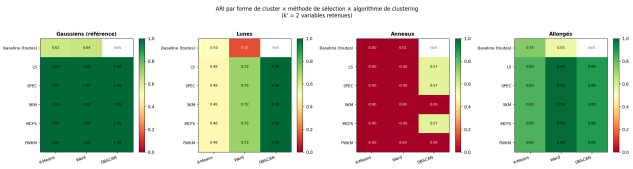

Figure 30: ARI par forme × méthode × algorithme de clustering. Sur gaussiens, la sélection *amélioré* K-Means (0,62 → 1,00). Sur les anneaux, K-Means échoue quelle que soit la sélection (ARI ≈ 0) : c'est une limite structurelle du clustering, pas de la sélection. DBSCAN avec les bonnes variables retrouvé 57% sur les anneaux — argument concret pour l'inclure au moins en exploration.

5.5.3 Étape 3 : qualité hors clustering

Trois outils permettent de juger la sélection *indépendamment* du clustering.

(a) Corrélation aux variables signal. Pour les k' variables sélectionnées, on mesure $|\rho|$ avec les vraies variables signal ; une méthode correcte atteint $|\rho| \approx 1$.

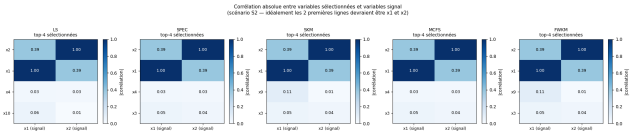

Figure 31: Corrélation des top-4 variables de chaque méthode avec x_1, x_2 (scénario S2). Toutes les méthodes placent effectivement x_1 et x_2 en rangs 1–2 avec $|\rho| = 1{,}00$. Les rangs 3–4 sont du bruit ($|\rho| < 0{,}1$). La sélection est donc valide indépendamment de l'algorithme de clustering utilisé ensuite.

(b) t-SNE. Projection 2D des sous-ensembles sélectionnés : si les vrais clusters restent séparables, la sélection préserve l'information structurelle.

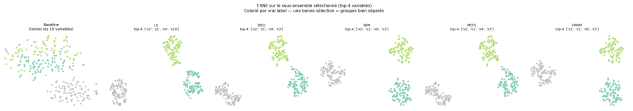

Figure 32: t-SNE sur les top-4 variables. Tous les panneaux montrent 3 clusters distincts : aucune méthode ne detruit l'information structurelle, même celles qui classent un peu de bruit dans le top-4. Test qualitatif complementaire aux mesures numériques.

(c) Scores LDA. Linear Discriminant Analysis cherche la projection maximisant la séparation linéaire entre classes. Score LDA élevé (validation croisée) $=$ sélection pertinente.

5.5.4 Étape 4 : stabilité et concordance

Une méthode performante peut être *instable* : $\{x_1, x_2\}$ sur l'ensemble, $\{x_1, x_7\}$ sur un sous-échantillon. Défaut majeur pour le CEA (règles reproductibles).

Stabilité bootstrap. $B = 50$ sous-échantillonnages a 80 %, indice de Jaccard moyen entre paires de top-k' :

$$J(S_a, S_b) = \frac{|S_a \cap S_b|}{|S_a \cup S_b|} \in [0, 1] \tag{19}$$

$J = 1$: sélection constante. $J \approx 0$: erratique.

Concordance entre méthodes (tau de Kendall) : $\tau_K \approx 1$ = méthodes redondantes, τ_K faible = aspects complementaires.

$$\tau_K = \frac{n_{\text{concord.}} - n_{\text{discord.}}}{d(d-1)/2} \in [-1, 1] \tag{20}$$

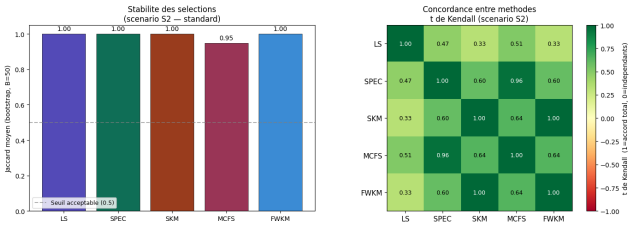

Figure 33: Stabilité bootstrap + concordance entre méthodes (S2). Gauche : sur S2, toutes les méthodes sont quasi-parfaitement stables ($J \geq 0{,}95$). Droite : la matrice Kendall révèle deux paires très concordantes — **SPEC** ↔ **MCFS** ($\tau = 0{,}96$) et **SKM** ↔ **FWKM** ($\tau = 1{,}00$, approches duales BCSS/WCSS). LS est la méthode la plus indépendante du lot. Conséquence pratique : inclure LS + une méthode de chaque cluster concordant suffit, le reste est redondant.

5.6 Tableau de bord

Les quatre dimensions sont agrégées par méthode :

- ARI moyen (Étape 2) : capacité à retrouver le signal.
- Stabilité bootstrap (Étape 4) : robustesse.
- Scores CEA (Étape 3) : trade-off qualité/réduction.
- Compatibilité FCM : extension naturelle au pipeline CEA.

Seuils minimaux : ARI $\geq 0{,}5$, Jaccard $\geq 0{,}5$, pas de dégradation Silhouette $> 0{,}05$ vs baseline.

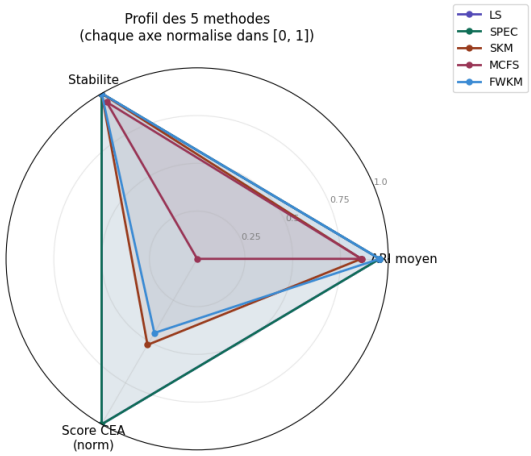

Figure 34: Profil radar des 5 méthodes sur 3 axes normalisés. LS/SPEC/FWKM dominent en ARI moyen et stabilité. **SPEC** maximise le score CEA. **SKM et MCFS** sont pénalisées par leurs échecs ponctuels. **FWKM** est le meilleur compromis global — et la seule compatible FCM.

Protocole complet. (1) Normaliser les scores en rangs. (2) Benchmarks synthétiques avec ARI post-sélection, incluant formes non gaussiennes. (3) Qualite hors clustering (corrélation, t-SNE, LDA). (4) Stabilité bootstrap + concordance Kendall. Les quatre dimensions sont nécessaires : une méthode peut dominer en ARI mais être instable, ou bien concordante avec une autre donc redondante.

VI. CONCLUSION

Avancement. Les quatre axes du projet sont en place, chacun dans un notebook dédié :

- **NB1 (Données)** : 9 datasets analysés, anomalies identifiées (zeros deguises `diabetes`, 26 paires corrélées `parkinsons`, 37 variables constantes `expt_gap`, 8/9 colonnes catégorielles `breast_cancer`, classe singleton `vehicle`). `matbench_steels` écarté (format corrompu) et sera remplacé. Pipeline standard verrouillé.
- **NB2 (Clustering)** : K-Means, Ward, FCM, DBSCAN implémentés *from scratch* et caractérisés sur 6 datasets synthétiques. Pipeline retenu : **FCM initialisé par Ward** (demarrage déterministe + partition floue pour Sugeno).
- **NB3 (Sélection)** : 5 méthodes couvrant les 3 familles (filter, wrapper, embedded) implémentées *from scratch*. Toutes retrouvent $\{x_1, x_2\}$ sur le jeu signal/bruit.
- **NB4 (Protocole)** : 4 étapes d'évaluation (rangs, ARI, qualité hors clustering, stabilité) avec 6 scénarios + 4 formes.

Resultats cles du benchmark synthétique.

- **LS, SPEC, FWKM** dominent en ARI moyen (0,95) ; SKM et MCFS sont pénalisés par des échecs ponctuels (ARI moyen 0,86).
- **LS** $\leftrightarrow$ **SPEC** et **SKM** $\leftrightarrow$ **FWKM** sont fortement concordants ($\tau_K > 0{,}9$) : redondants, en garder un de chaque paire suffit.
- **FWKM** est la seule méthode *nativement compatible avec FCM* : c'est la piece manquante pour le système de Sugeno du CEA.
- Sur formes non-convexes, *la sélection seule ne sauve rien* : il faut DBSCAN pour retrouver la structure. Argument concret pour le reintroduire en exploration.

Limites et étapes suivantes.

1. Appliquer le protocole complet sur les 9 datasets réels, priorité a `expt_gap` ($d = 135$), cas le plus discriminant.
2. Valider empiriquement le paramètre λ du score CEA avec les encadrants.
3. Etendre explicitement FWKM au FCM et comparer a sa version K-Means.
4. Methodologie spécifique pour données mixtes (`breast_cancer`, `covertype`), s'appuyant sur Warkiani & Moattar (2025).
5. Veille sur HDBSCAN et sélection associee aux clusterings de densité.

Livrables

Quatre notebooks : `01_data_analysis_preprocessing`, `02_clustering_methods`, `03_variable_selection`, `04_evaluation_protocol`.

RÉFÉRENCES

Alelyani, Tang & Liu (2013) "Feature Sélection for Clustering: A Review". *Data Clustering: Algorithms and Applications*, CRC Press.

Arthur & Vassilvitskii (2007) "k-means++: The advantages of careful seeding". *SODA '07*, 1027–1035.

Bezdek, Ehrlich & Full (1984) "FCM: The Fuzzy C-Means Clustering Algorithm". *Computers & Geosciences*, 10(2–3), 191–203.

Cai, Zhang & He (2010) "Unsupervised Feature Sélection for Multi-Cluster Data". *KDD '10*, 333–342.

Ester, Kriegel, Sander & Xu (1996) "A density-based algorithm for discovering clusters in large spatial databases with noise". *KDD '96*, 226–231.

He, Cai & Niyogi (2005) "Laplacian Scores for Feature Sélection". *NIPS 18*.

Jain (2010) "Data clustering: 50 years beyond K-means". *Pattern Recognition Letters*, 31(8), 651–666.

Lloyd (1982) "Least squares quantization in PCM". *IEEE Trans. Information Theory*, 28(2), 129–137.

Meredig et al. (2014) "Combinatorial screening for new materials in unconstrained composition space with machine learning". *Phys. Rev. B*, 89(9), 094104.

Modha & Spangler (2003) "Feature weighting in k-means clustering". *Machine Learning*, 52(3), 217–237.

Rousselle, Poli & Ben Abdallah (2024) "Fuzzy active learning for matériel science". Note technique CEA-LIST.

Shi & Malik (2000) "Normalized cuts and image segmentation". *IEEE PAMI*, 22(8), 888–905.

Ward (1963) "Hierarchical grouping to optimize an objective function". *JASA*, 58(301), 236–244.

Warkiani & Moattar (2025) "Recent advances in features sélection for mixed-type data". *preprint*.

Witten & Tibshirani (2010) "A framework for features sélection in clustering". *JASA*, 105(490), 713–726.

Xu & Wunsch (2005) "Survey of Clustering Algorithms". *IEEE Trans. Neural Networks*, 16(3), 645–678.

Yeh (1998) "Modeling of strength of high-performance concrète using artificial neural networks". *Cement and Concrété Research*, 28(12), 1797–1808.

Zhao & Liu (2007) "Spectral features sélection for supervised and unsupervised learning". *ICML '07*, 1151–1157.

ANNEXE A — FIGURES EN GRAND FORMAT

Cette annexe regroupe l'ensemble des figures du rapport au format pleine largeur pour faciliter leur lecture. L'ordre suit celui du document (Donnees, Clustering, Selection, Protocole).

A.1 Donnees (Partie II)

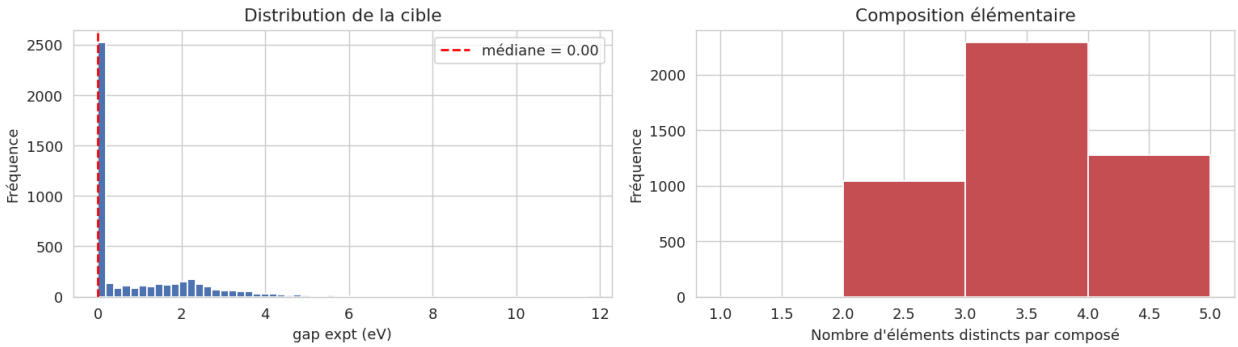

Fig. 1 — Exploration de `expt_gap`. Distribution bimodale du gap (conducteurs vs. semi-conducteurs/isolants) et composition elementaire (peu de materiaux utilisent plus de 4 elements).

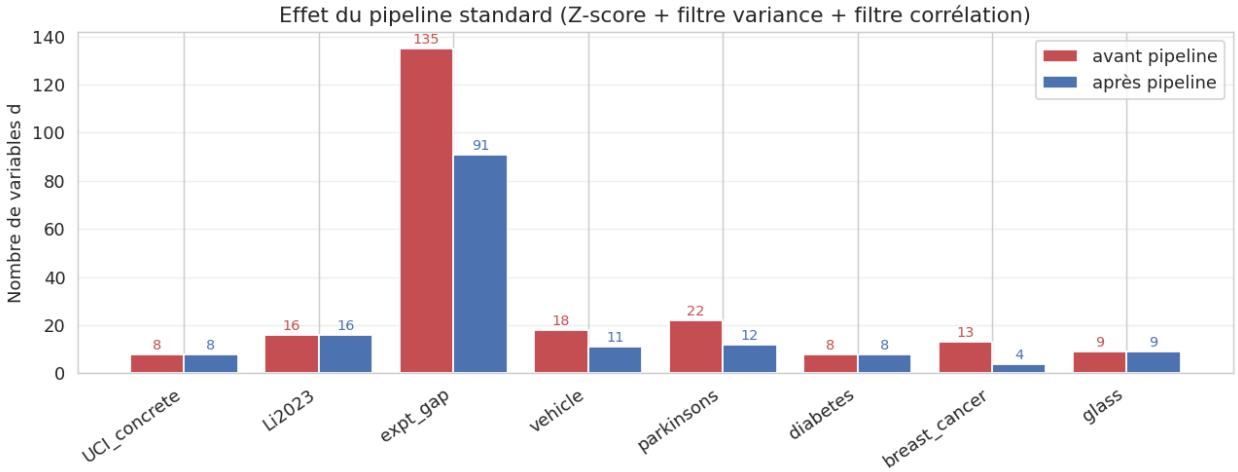

Fig. 3 — Effet du pipeline standard par dataset (avant vs. apres).

A.2 Clustering (Partie III)

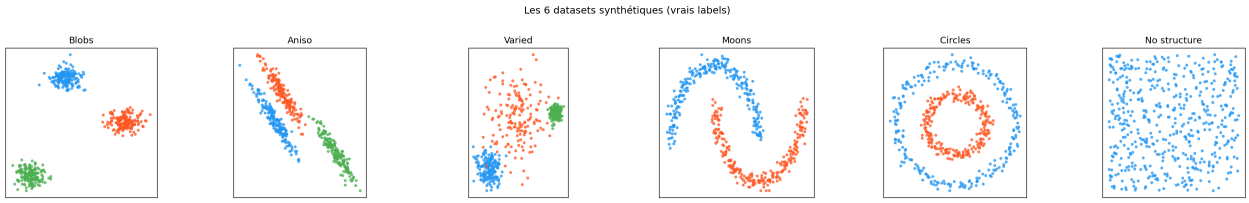

Fig. 4 — Les 6 datasets synthetiques utilises pour visualiser les algorithmes.

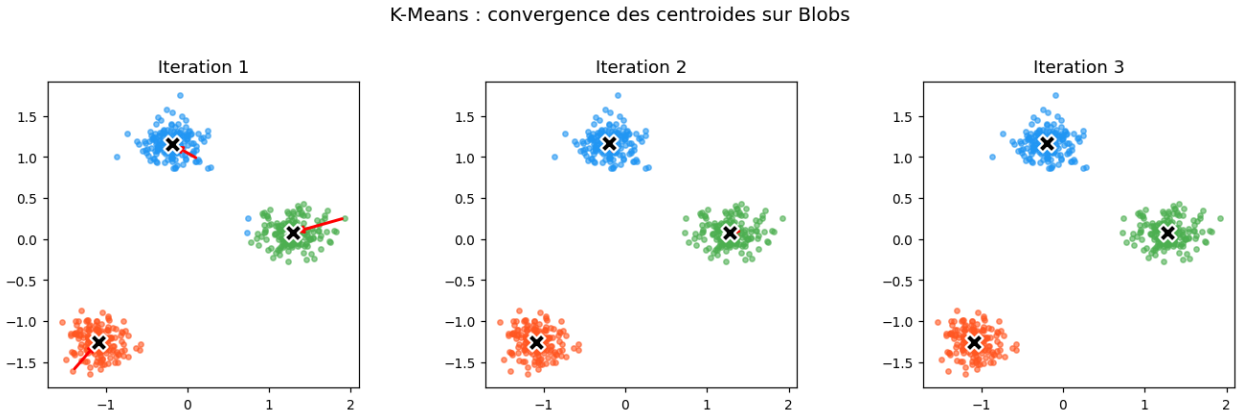

Fig. 5 — K-Means sur *Blobs* : convergence des centroides en 3 iterations.

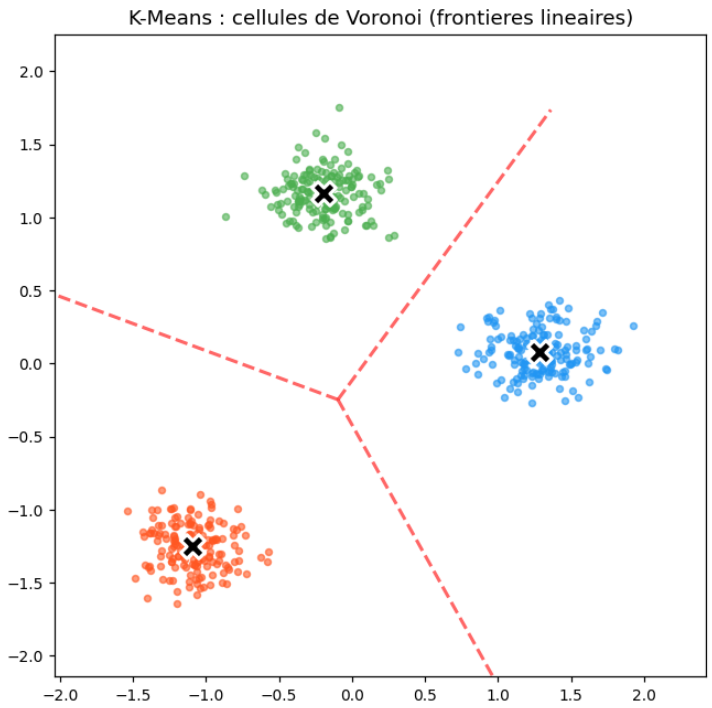

Fig. 6 — Cellules de Voronoi : frontieres lineaires.

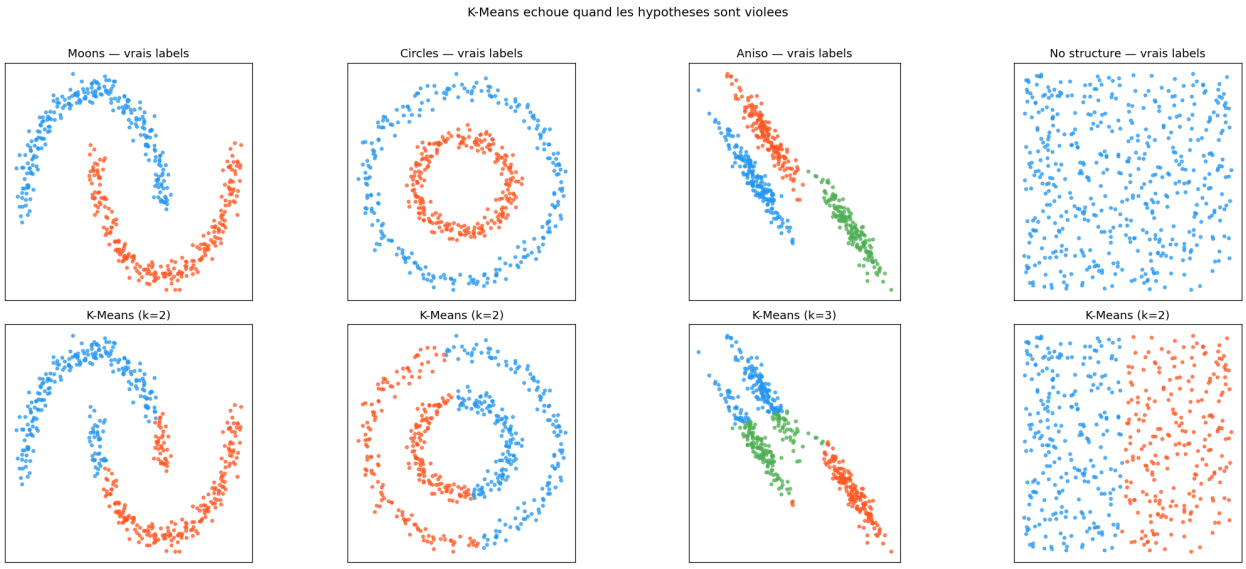

Fig. 7 — Cas d'echec de K-Means (formes non convexes, clusters allonges, absence de structure).

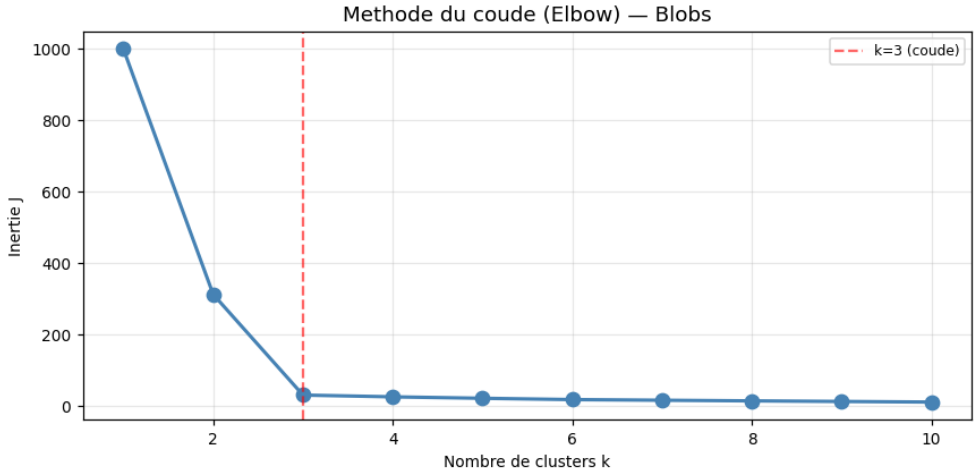

Fig. 8 — Methode du coude sur *Blobs*.

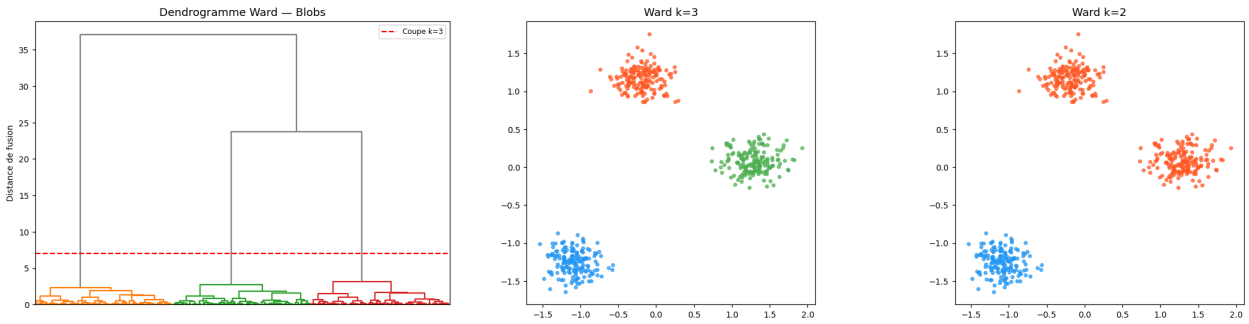

Fig. 9 — Dendrogramme Ward avec coupes a $k = 3$ et $k = 2$.

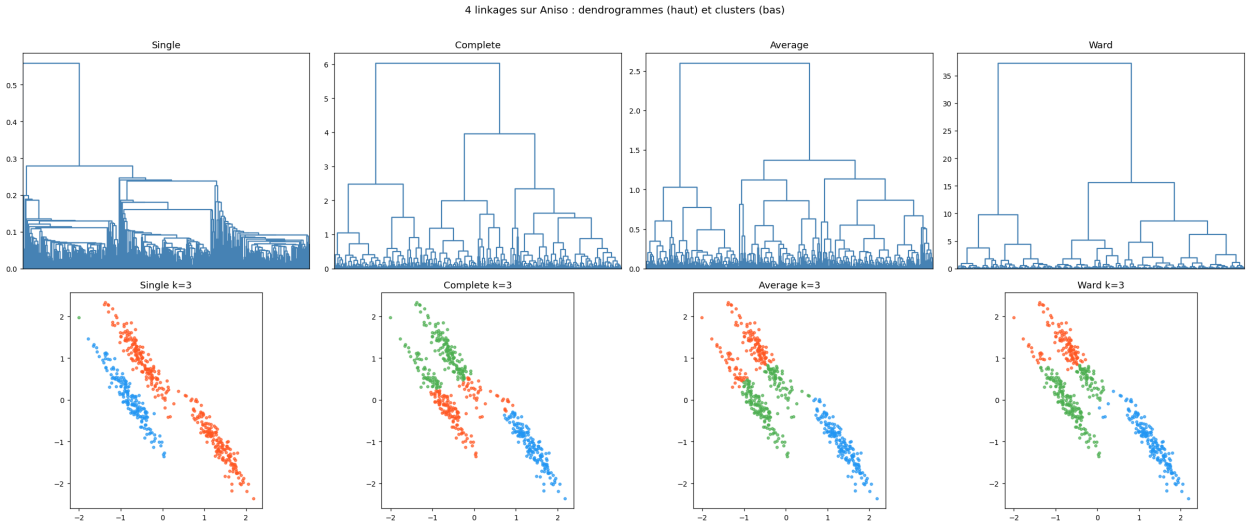

Fig. 10 — Les 4 linkages sur *Aniso* : dendrogrammes et clusters obtenus.

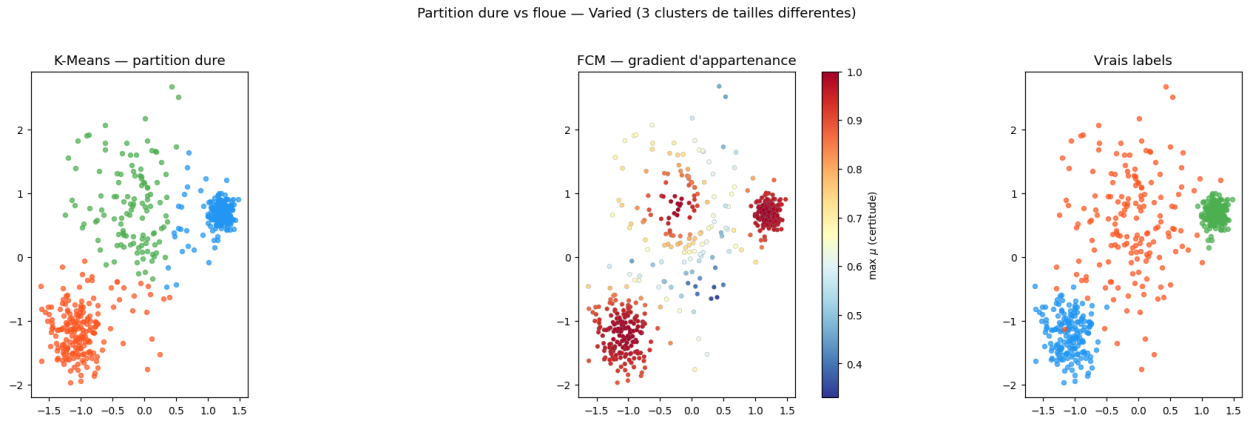

Fig. 11 — K-Means dur vs. FCM flou : certitude d'appartenance.

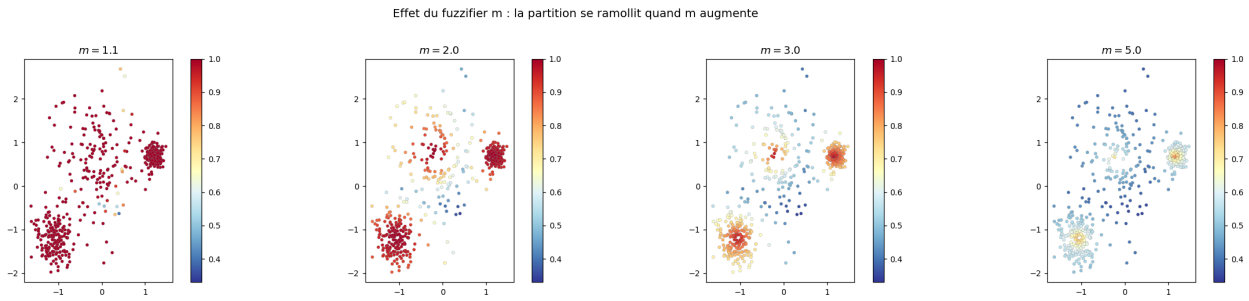

Fig. 12 — Effet du fuzzifier m sur la partition FCM.

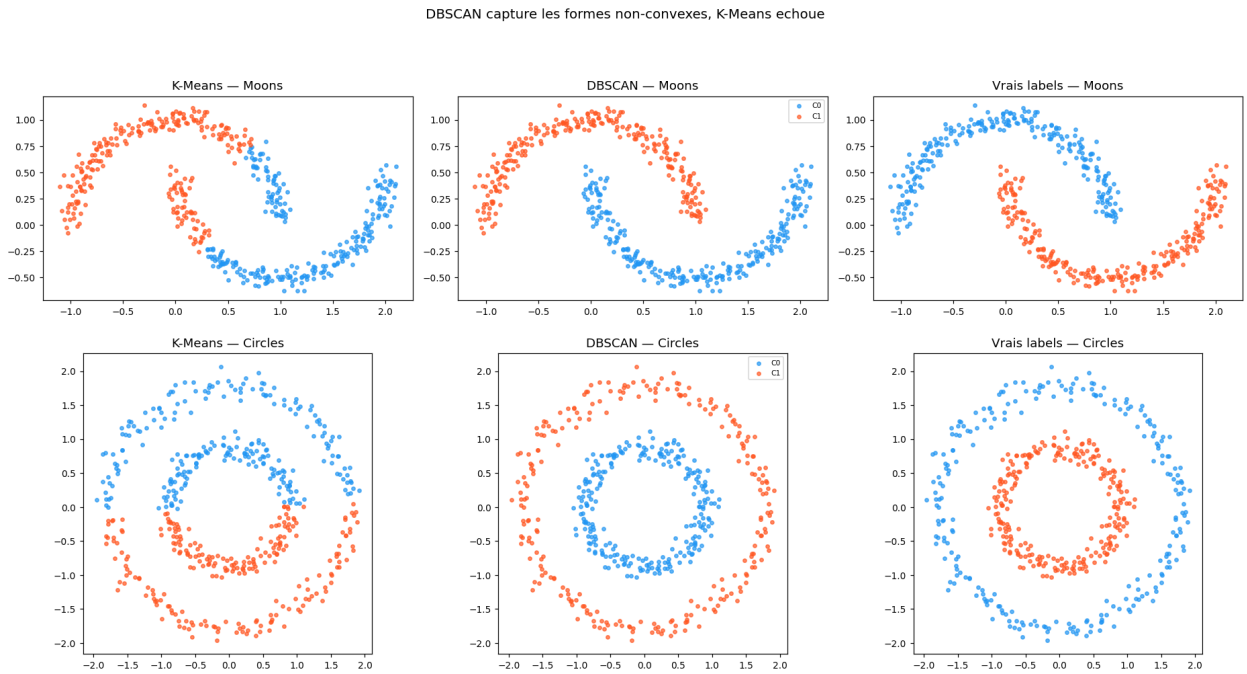

Fig. 13 — DBSCAN reussit sur *Moons* et *Circles* la ou K-Means echoue.

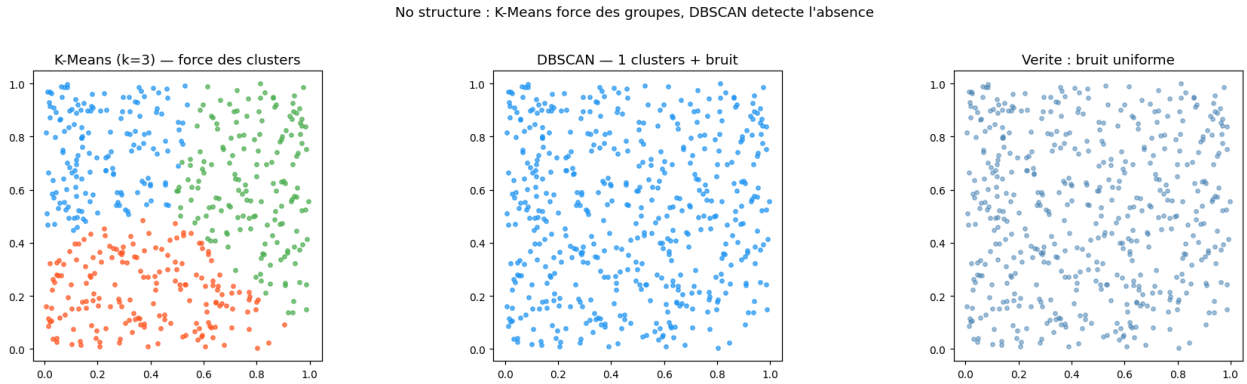

Fig. 14 — DBSCAN detecte l'absence de structure ; K-Means invente des clusters.

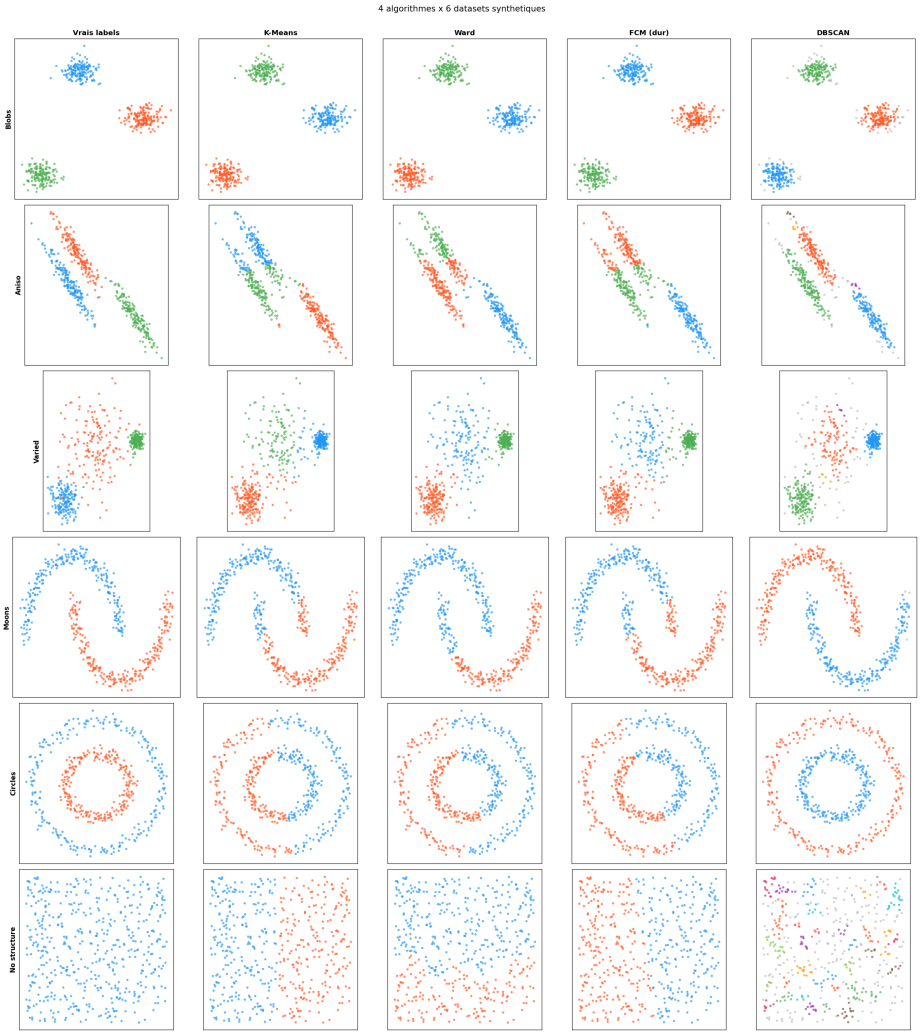

Fig. 15 — Grille comparative : 4 algorithmes × 6 datasets synthetiques.

A.3 Selection de variables (Partie IV)

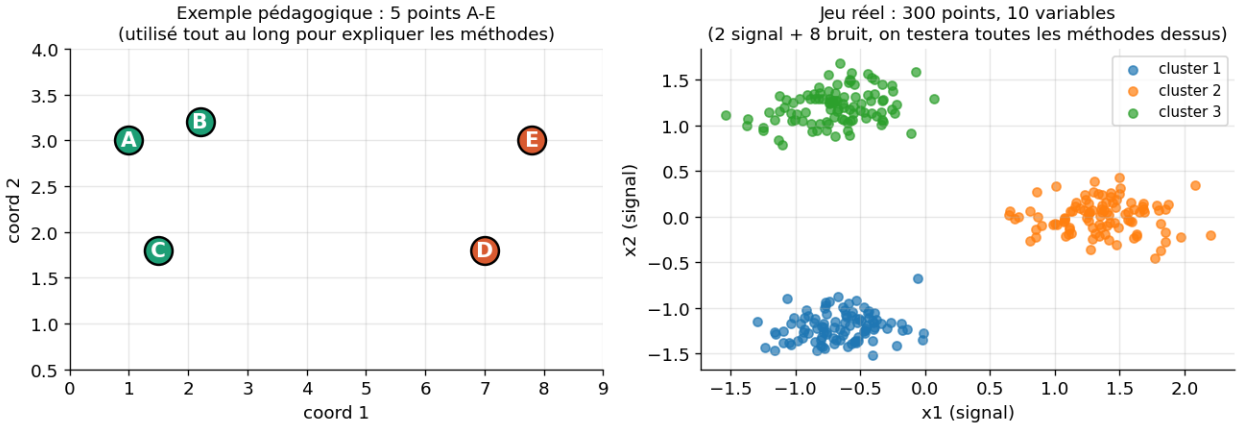

Fig. 16 — Les deux jeux de donnees : fil rouge pedagogique (5 points) et jeu realiste (300 points, 10 variables).

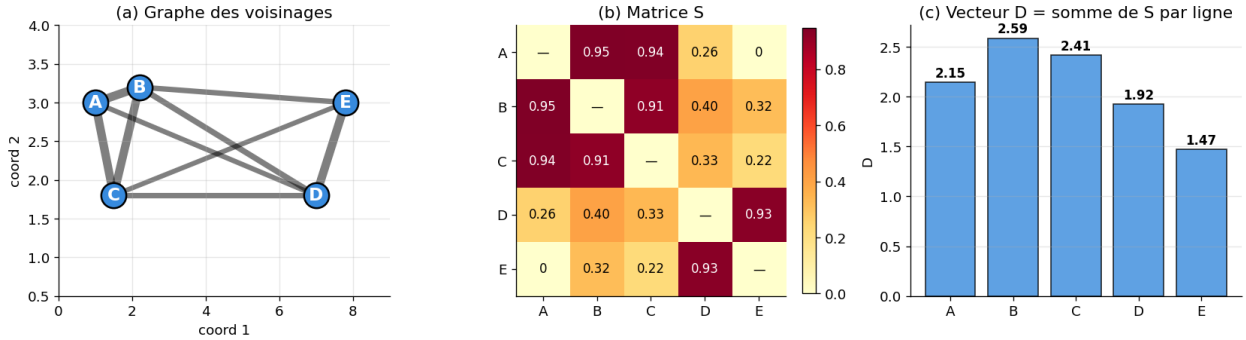

Fig. 17 — Les trois objets de base : graphe k-NN, matrice de similarite S, vecteur des degres D.

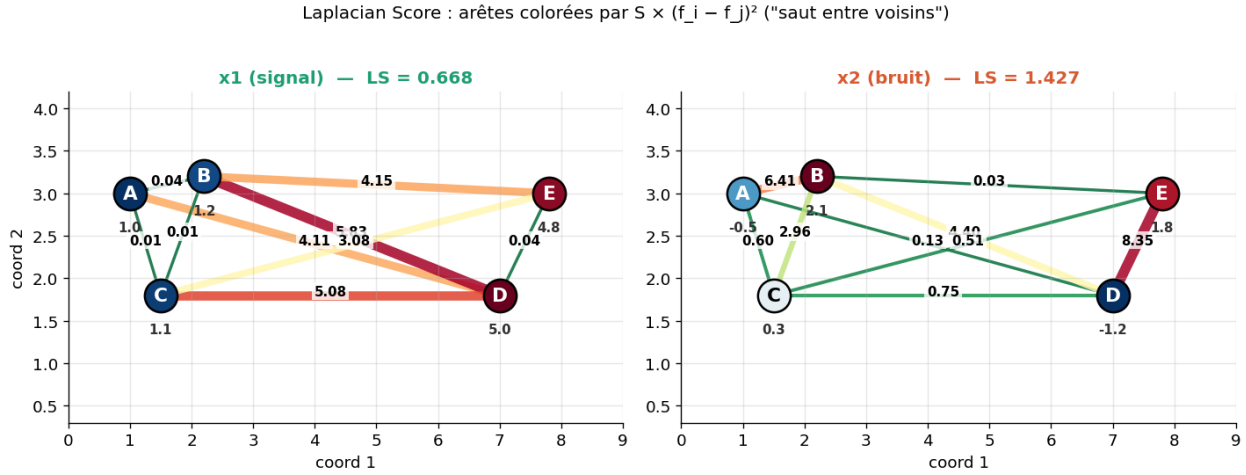

Fig. 18 — Laplacian Score : variable signal lisse (aretes fines) vs. variable bruit rugueuse (aretes epaisses).

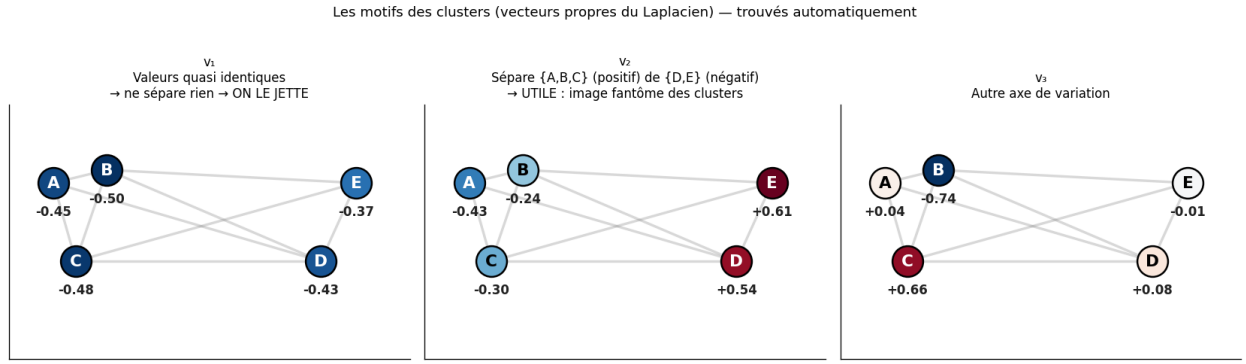

Fig. 19 — Vecteurs propres du Laplacien colores sur le graphe : v_1 constant, v_2 et v_3 separent les groupes.

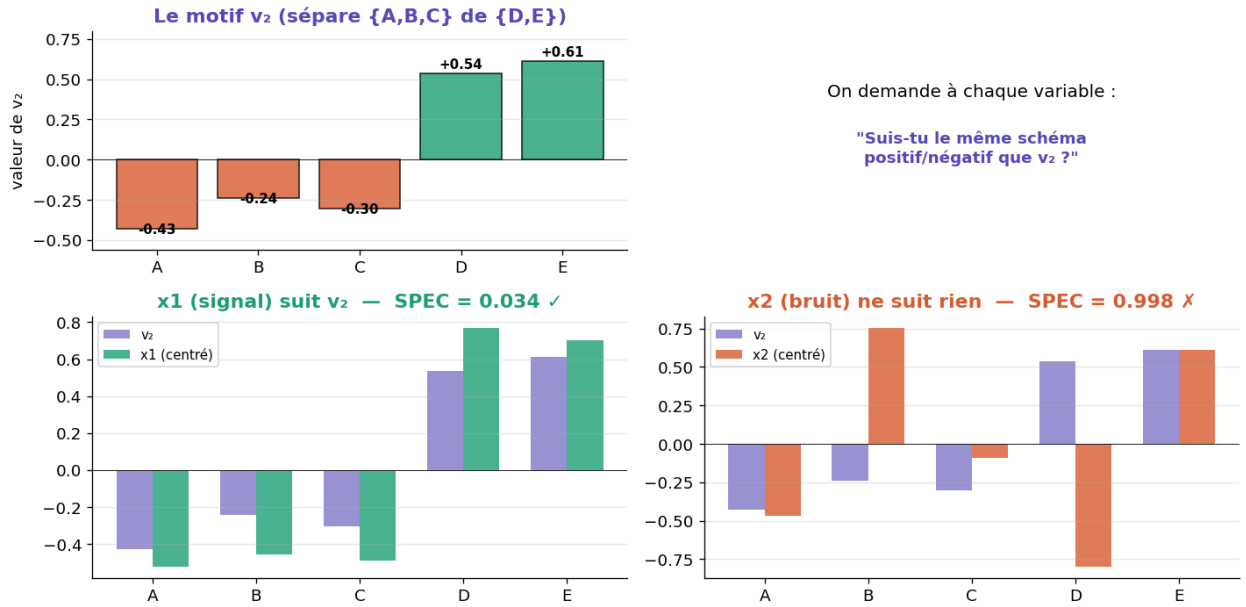

Fig. 20 — SPEC : la variable signal suit le motif v_2, la variable bruit ne suit aucun motif.

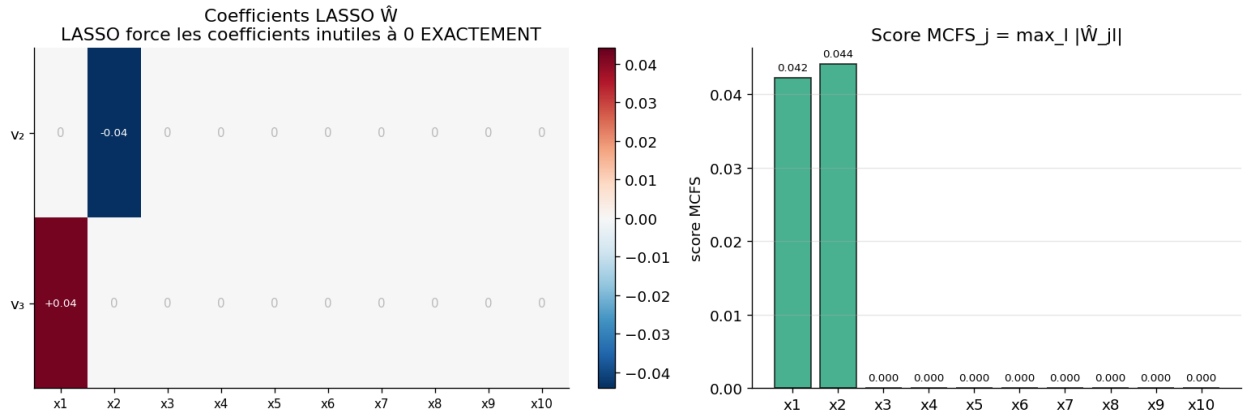

Fig. 21 — MCFS : heatmap des coefficients LASSO $\hat{W}$ et score = max ligne par ligne.

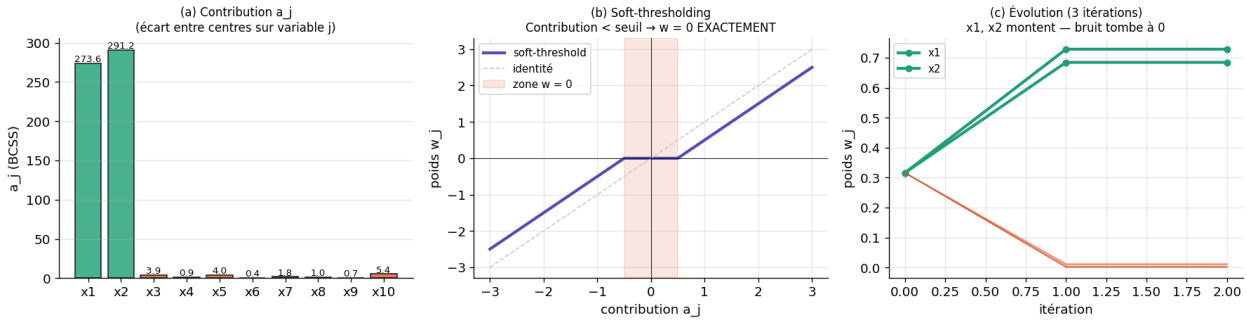

Fig. 22 — Sparse K-Means : contributions a_j, soft-thresholding, evolution des poids au cours des iterations.

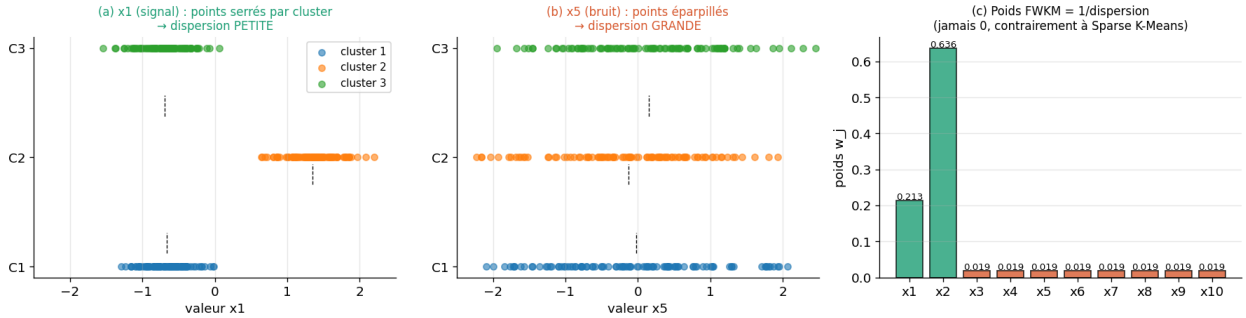

Fig. 23 — FWKM : dispersion intra-cluster petite (signal) vs. grande (bruit), poids inversement proportionnels.

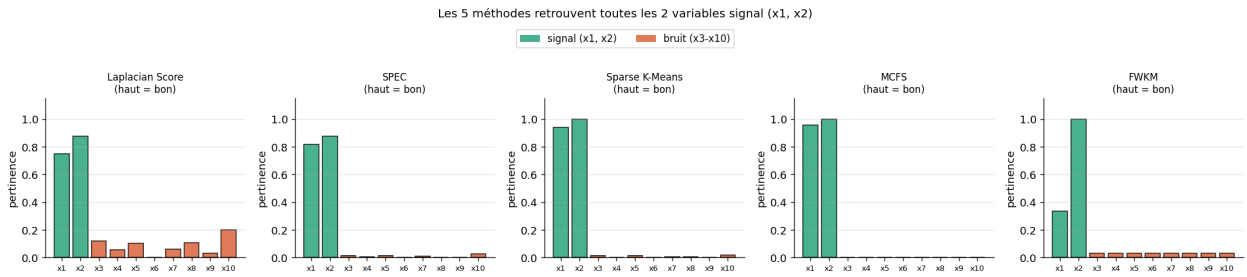

Fig. 24 — Resultat visuel des 5 methodes : toutes identifient x_1 et x_2 comme variables signal.

A.4 Protocole d'evaluation (Partie V)

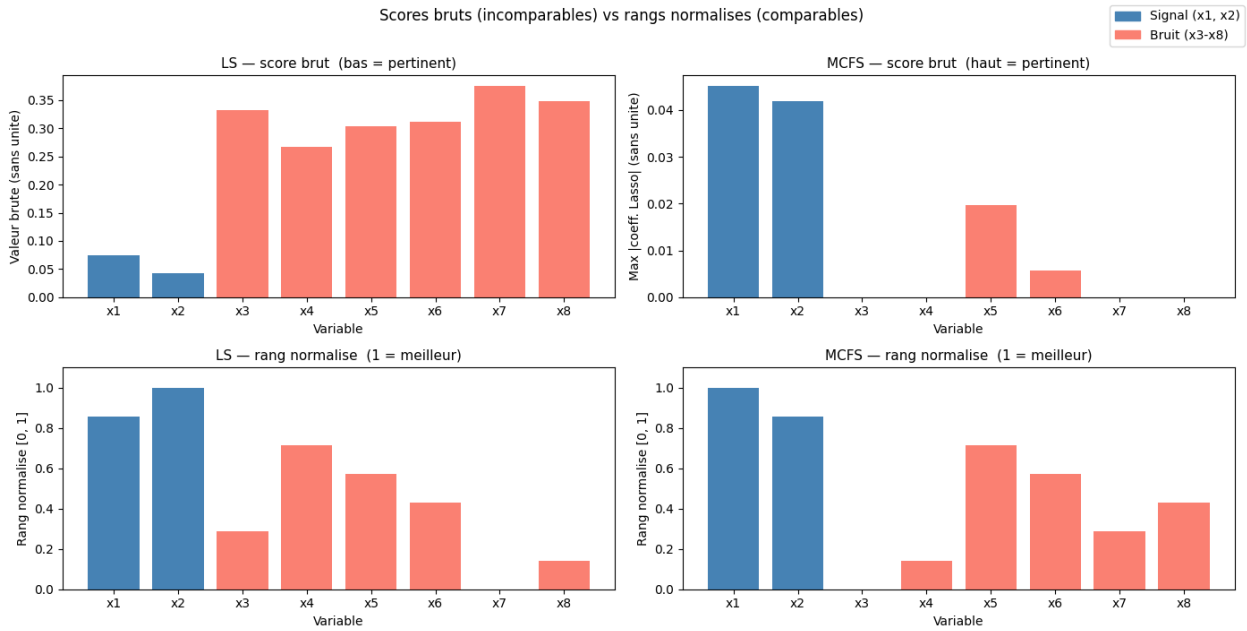

Fig. 26 — Scores bruts (incomparables) vs. rangs normalises (comparables).

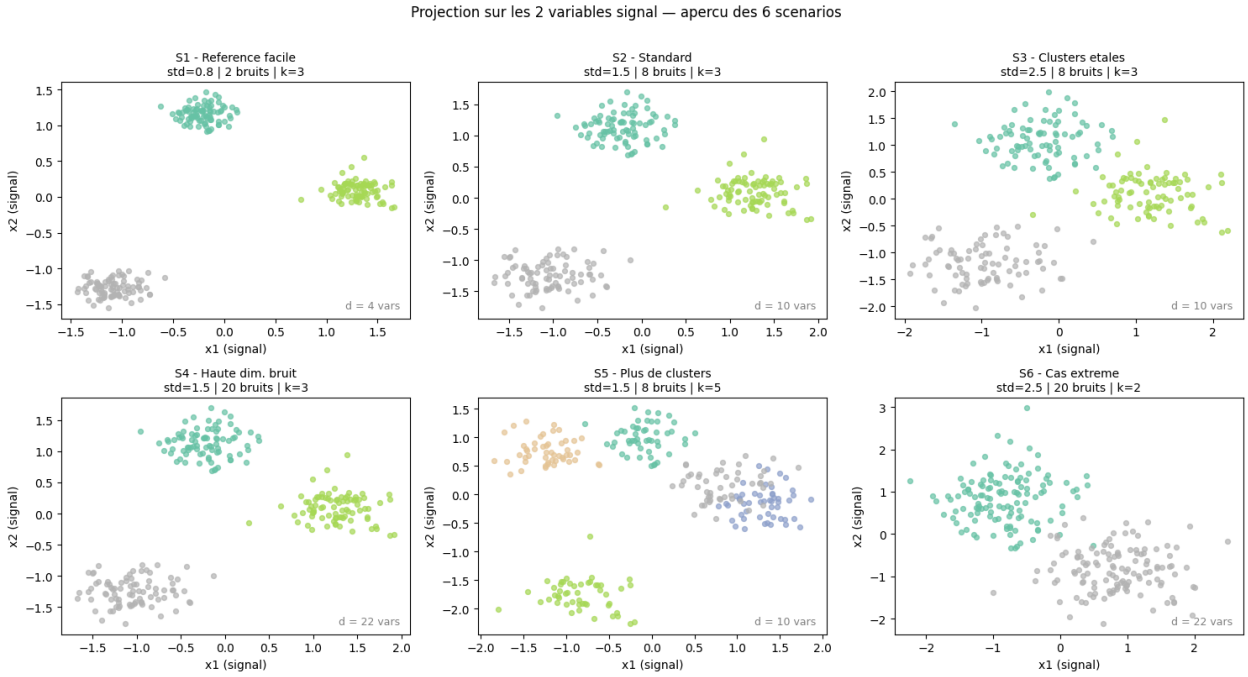

Fig. ?? — Les 6 scenarios synthetiques projetes sur (x_1, x_2).

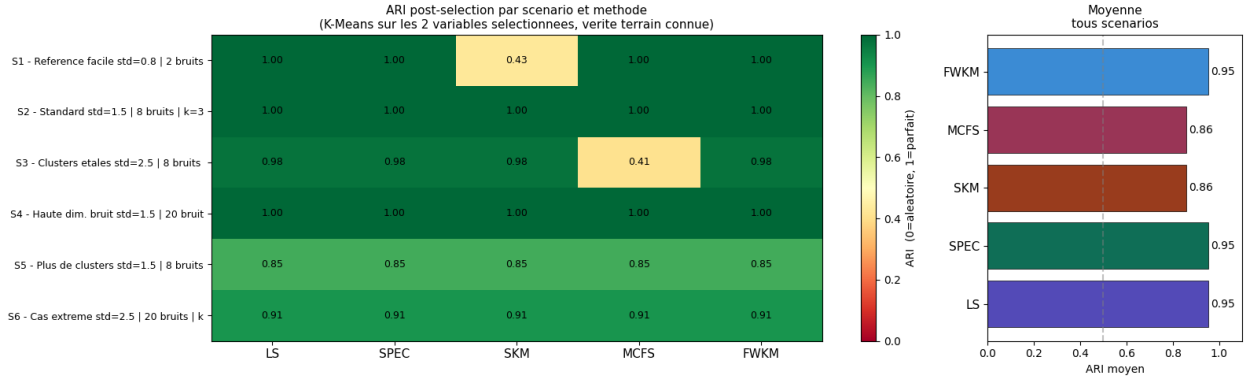

Fig. 28 — ARI post-selection par scenario × methode + ARI moyen.

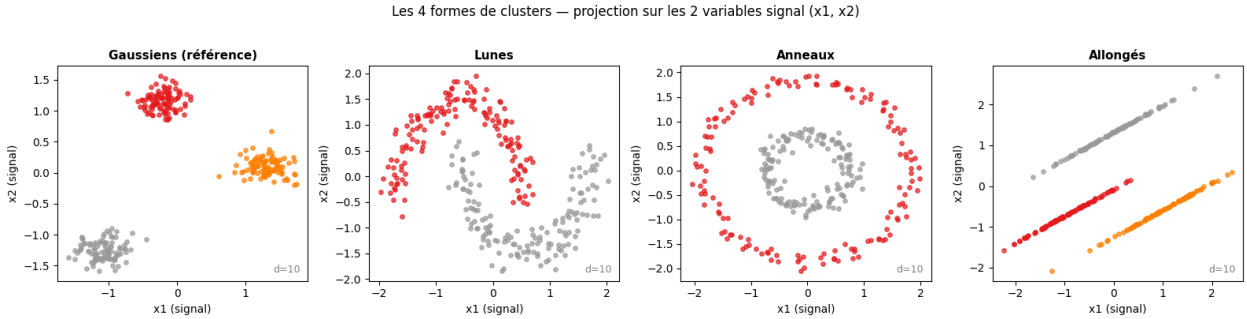

Fig. 29 — Les 4 formes de clusters testees : gaussiens, lunes, anneaux, allonges.

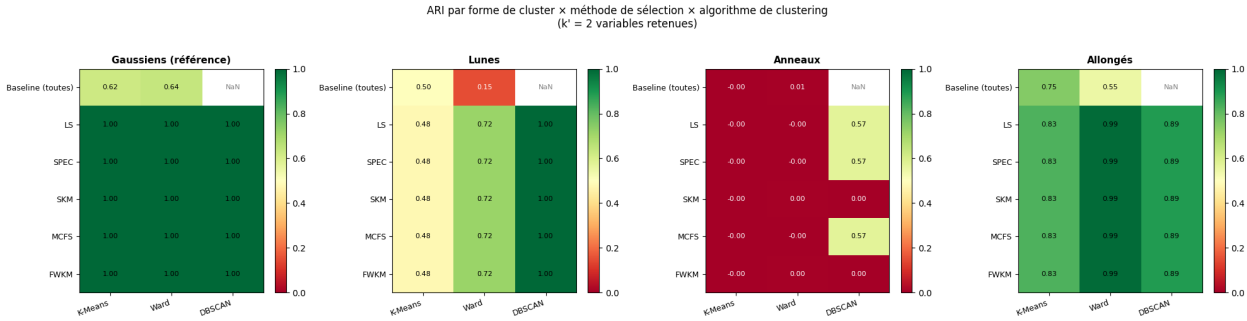

Fig. 30 — ARI par forme × methode de selection × algorithme de clustering.

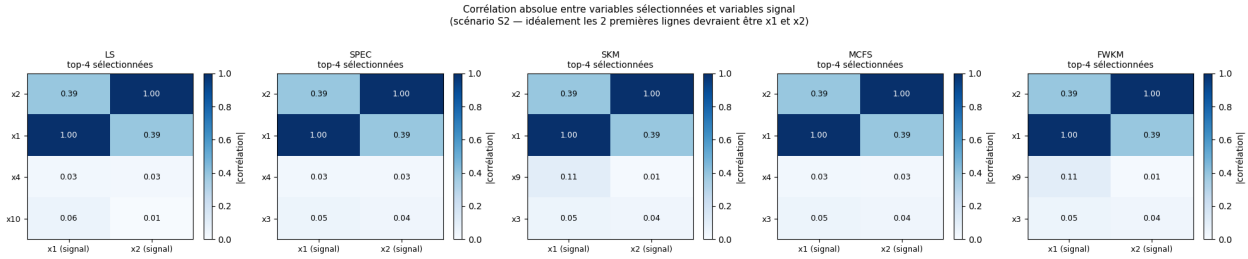

Fig. 31 — Correlation absolue entre variables selectionnees et variables signal.

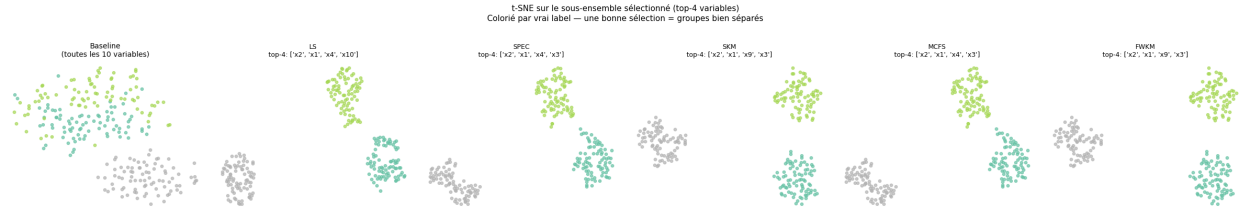

Fig. 32 — t-SNE sur les sous-ensembles selectionnes par chaque methode.

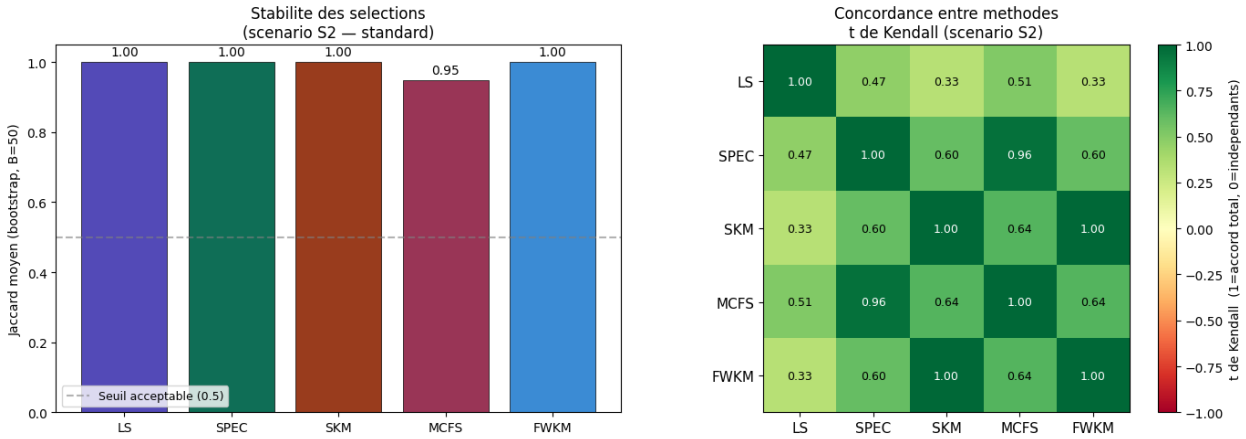

Fig. 33 — Stabilite bootstrap (Jaccard) et concordance entre methodes (Kendall τ).

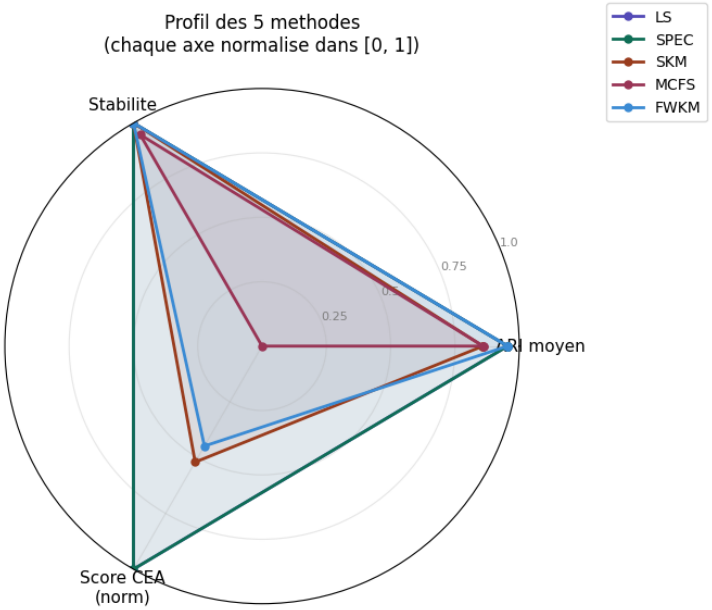

Fig. 34 — Profil radar des 5 methodes sur 3 axes normalises : ARI moyen, stabilite, score CEA.